


Fundamentos de IA Machine Learning e Modelos de Linguagem



Fundamentos de IA, ML, Deep Learning e IA Generativa



Karen Albergaria

Cloud Security Engineer



Apaixonada por **tecnologia, segurança** e por ajudar pessoas a **crescerem na nuvem**.

ÁREAS DE ATUAÇÃO



Cloud Security



Governança e Compliance



Monitoramento e Resposta



Treinamento e Mentoria

CERTIFICAÇÕES



MISSÃO

Tornar a nuvem um ambiente mais seguro e confiável para todos.



VISÃO

Continuar aprendendo, compartilhando e impulsionando carreiras.



VALORES

Ética, colaboração, curiosidade e responsabilidade.

escola
da
nuvem.

www.escoladanuvem.org

Agenda

01 IA, ML, Deep Learning e IA Generativa

Definições, diferenças e relação entre os conceitos

02 Redes Neurais

A base computacional dos modelos modernos

04 LLMs e SLMs

Modelos de linguagem grandes e pequenos

03 Conceitos-chave

Modelo, algoritmo, treinamento e inferência

05 Transformers e Dimensões

Arquitetura moderna e espaço vetorial

M Ó D U L O

01

IA, ML, Deep Learning e IA Generativa


Definindo os termos fundamentais e entendendo como se relacionam entre si

O que é Inteligência Artificial?

Definição

- Campo da computação que busca criar sistemas capazes de realizar tarefas que exigiriam inteligência humana
- Inclui percepção, raciocínio, aprendizado, decisão e linguagem
- É uma área ampla que abrange diversas técnicas e abordagens
- ML e Deep Learning são subáreas dentro da IA

Hierarquia conceitual



Machine Learning (ML)

Definição

- Subárea da IA em que sistemas aprendem padrões a partir de dados, sem serem explicitamente programados
- Em vez de regras fixas, o sistema descobre relações estatísticas nos dados
- Quanto mais dados de qualidade, melhor tende a ser o aprendizado
- É a base para previsões, classificações e recomendações

Supervisionada

O modelo aprende a partir de exemplos rotulados — entrada e resposta correta

Não supervisionada

O modelo descobre padrões e agrupamentos em dados sem rótulos

Por reforço

O modelo aprende por tentativa e erro recebendo recompensas e penalidades

Deep Learning

Definição

- Ramo do Machine Learning baseado em redes neurais profundas, com múltiplas camadas
- Capaz de aprender representações complexas diretamente dos dados brutos
- Especialmente eficaz em imagens, áudio, vídeo e texto
- Exige grande volume de dados e poder computacional elevado
- É o motor por trás de avanços recentes em visão computacional e linguagem natural

DESTAQUE

Profundidade

O termo "deep" refere-se ao número de camadas escondidas na rede neural quanto mais camadas, maior a capacidade de capturar padrões abstratos.

IA Generativa

Definição

- Categoria de IA capaz de criar novos conteúdos a partir do que aprendeu
- Pode gerar texto, imagens, áudio, vídeo, código e dados sintéticos
- Diferente da IA tradicional, que apenas classifica, prevê ou identifica
- Apoia-se em modelos de Deep Learning de grande escala
- Está na base dos modelos de linguagem que estudaremos mais adiante

Exemplos de geração

Texto

Resumos, redações, código

Imagem

Ilustrações e edições

Áudio

Voz, música, efeitos

Vídeo

Animações curtas

IA, ML, DL e IA Generativa: como se relacionam

Conceito	Foco	Característica principal
Inteligência Artificial	Simular capacidades humanas	Campo amplo que abrange ML, DL e mais
Machine Learning	Aprender padrões a partir de dados	Não depende de regras programadas manualmente
Deep Learning	Representações complexas	Usa redes neurais profundas com múltiplas camadas
IA Generativa	Criar novo conteúdo	Apoia-se em DL para gerar texto, imagem, áudio

Cada conceito está contido no anterior: IA -> ML -> DL -> IA Generativa

M Ó D U L O

02

Redes Neurais


A base computacional que torna possível o aprendizado profundo e os modelos de linguagem modernos

O que é uma Rede Neural?

Definição

- Estrutura computacional inspirada no funcionamento do cérebro humano
- Composta por unidades chamadas neurônios artificiais, organizadas em camadas
- Cada conexão entre neurônios possui um peso ajustável durante o treinamento
- Recebe entradas, processa em camadas intermediárias e produz uma saída
- É a estrutura matemática que permite o Deep Learning

Estrutura básica



Como uma rede neural aprende?

1

Recebe os dados

As entradas chegam pela primeira camada da rede

2

Faz uma previsão

A informação é processada nas camadas e gera uma saída

3

Compara com o esperado

Calcula o erro entre o resultado obtido e a resposta correta

4

Ajusta os pesos

Modifica as conexões para reduzir o erro nas próximas tentativas

O ciclo se repete milhões de vezes até a rede estabilizar em uma boa precisão

Principais tipos de redes neurais

Redes Feedforward

Informação flui em uma única direção, da entrada para a saída. Base de muitos modelos.

Redes Convolucionais (CNN)

Especializadas em imagens e dados com estrutura espacial.

Redes Recorrentes (RNN)

Processam sequências, mantendo memória de elementos anteriores.

Transformers

Arquitetura moderna que substituiu as RNN para texto e linguagem natural.

M Ó D U L O

03

Conceitos-chave

Modelo, algoritmo, treinamento, inferência e a introdução aos LLMs

Cinco conceitos que você precisa dominar

01	02	03	04	05
Modelo	Algoritmo	Treinamento	Inferência	LLMs
Resultado matemático do aprendizado, capaz de fazer previsões	Procedimento usado para treinar e ajustar o modelo	Fase em que o modelo aprende a partir dos dados	Uso do modelo treinado para gerar respostas novas	Modelos de linguagem de grande escala que veremos em detalhe

Modelo

Definição

- É o resultado do processo de aprendizado sobre os dados
- Funciona como uma função matemática que transforma uma entrada em uma saída
- Contém o conhecimento extraído dos exemplos vistos no treinamento
- Pode ser salvo, distribuído e reutilizado posteriormente
- A qualidade do modelo depende dos dados e do algoritmo usados

ANALOGIA

Receita aprendida

Pense no modelo como uma receita matemática que aprendeu a transformar ingredientes (entradas) em pratos (saídas) a partir de muitos exemplos.

Algoritmo

Definição

- Conjunto de passos lógicos que define como o modelo será treinado
- Determina a forma como os pesos são ajustados durante o aprendizado
- Existem diversos algoritmos, cada um adequado a um tipo de problema
- Não confundir com o modelo: o algoritmo é o método, o modelo é o resultado
- Exemplos clássicos incluem regressão, árvores de decisão e redes neurais

Distinção essencial

Algoritmo

É o método: o conjunto de passos para chegar ao modelo

Modelo

É o resultado: o que se obtém depois de aplicar o algoritmo aos dados

Treinamento

Definição

- Fase em que o algoritmo processa os dados e ajusta o modelo
- Costuma exigir grande volume de dados de qualidade
- É a etapa que mais consome tempo e poder computacional
- Geralmente realizada com hardware especializado, como GPUs
- O resultado é um modelo pronto para ser usado

Características

Custo alto

Computação e energia intensos

Tempo longo

Horas, dias ou semanas

Dados massivos

Volume grande e diverso

Acontece uma vez

Antes do modelo entrar em uso

Inferência

Definição

- Fase em que o modelo treinado é usado para gerar respostas
- Recebe novas entradas e produz previsões, classificações ou conteúdos
- Acontece em tempo real ou em lote, dependendo da aplicação
- Tem custo computacional menor que o treinamento, porém recorrente
- É a fase em que o usuário final efetivamente interage com a IA

TREINAMENTO × INFERÊNCIA

Quando?

Treinamento: Antes do uso

Inferência: Durante o uso

Custo?

Treinamento: Muito alto

Inferência: Mais baixo

Frequência?

Treinamento: Pontual

Inferência: Contínua

Apresentando os LLMs

Definição

- Sigla para Large Language Models, ou modelos de linguagem de grande escala
- Modelos treinados em volumes massivos de texto
- Capazes de entender e gerar linguagem natural com fluência
- Geralmente baseados na arquitetura Transformer
- Veremos LLMs em profundidade no próximo módulo

LLMs estão na base de assistentes virtuais, mecanismos de busca conversacionais e ferramentas de produtividade

M Ó D U L O

04

Large Language Models (LLMs)

Modelos de linguagem de grande escala que protagonizam a IA
Generativa atual

O que são LLMs?

Definição

- Treinados com bilhões ou trilhões de tokens de texto
- Possuem dezenas a centenas de bilhões de parâmetros
- Capazes de raciocinar, resumir, traduzir, programar e dialogar
- Servem como base para muitas aplicações de IA Generativa
- Modelos de Deep Learning especializados em linguagem natural

Bilhões

de parâmetros ajustados durante o
treinamento

Trilhões

de tokens vistos durante o pré-treinamento

Como funcionam os LLMs?

Definição

- Recebem um texto de entrada chamado prompt
- Quebram o texto em tokens, que são pedaços menores como palavras ou subpalavras
- Calculam, a cada passo, qual é o próximo token mais provável
- Geram a resposta token por token, formando frases coerentes
- Não pesquisam na internet em tempo real, respondem com base no que aprenderam

Capacidades e limitações dos LLMs

Capacidades

- Compreender e gerar texto fluente
- Resumir, traduzir e reescrever conteúdos
- Responder perguntas em linguagem natural
- Auxiliar na escrita de código
- Explicar conceitos de forma adaptada ao público

Limitações

- Podem gerar respostas incorretas com tom de certeza
- Conhecimento limitado pela data do treinamento
- Não compreendem o mundo, apenas modelam padrões de texto
- Custo elevado de computação e infraestrutura
- Riscos relacionados a privacidade, viés e segurança

M Ó D U L O

05

Small Language Models (SLMs)


Modelos de linguagem menores, mais rápidos e adequados a cenários específicos

O que são SLMs?

Definição

- Sigla para Small Language Models, ou modelos de linguagem de pequena escala
- Possuem ordens de grandeza menos parâmetros que os LLMs
- São treinados com volumes menores e mais focados de dados
- Mais rápidos, mais baratos e exigem menos infraestrutura
- Podem rodar localmente, em servidores menores ou até em dispositivos finais

SLMs vs LLMs



LLMs versus SLMs

Aspecto	LLMs	SLMs
Tamanho	Bilhões de parâmetros	Milhões a poucos bilhões
Custo	Alto para treinar e operar	Baixo a moderado
Velocidade	Inferência mais lenta	Inferência mais rápida
Generalização	Ampla, em muitos domínios	Mais focada em tarefas específicas
Onde executar	Nuvem com hardware potente	Pode rodar local ou em borda

Quando preferir um SLM?

Tarefas focadas	O problema é específico e bem delimitado, sem precisar de generalização ampla
Restrição de custo	Operação contínua exige redução de custo de inferência
Latência baixa	É necessária resposta muito rápida em tempo real
Privacidade dos dados	Os dados não devem sair do ambiente local ou da rede da empresa
Hardware limitado	O modelo precisa rodar em servidores modestos ou em dispositivos finais

M Ó D U L O

06

Modelos de Linguagem baseados em Transformer

A arquitetura que viabilizou os LLMs e a IA Generativa modernos

Origem dos Transformers

Definição

- Arquitetura proposta em pesquisa publicada em 2017
- Surgiu para resolver limitações das redes recorrentes em sequências longas
- Trouxe um mecanismo central chamado atenção
- Permitiu treinar modelos muito maiores em paralelo
- Tornou-se a base de praticamente todos os LLMs modernos

MARCO TÉCNICO

2017

Ano em que a arquitetura Transformer foi apresentada e mudou o rumo do processamento de linguagem natural.

Como é a arquitetura Transformer?

Definição

- Composta por blocos empilhados que processam o texto em paralelo
- Cada bloco combina mecanismos de atenção e camadas neurais
- Trabalha com representações vetoriais dos tokens chamadas embeddings
- Captura relações entre palavras independentemente da distância no texto
- Pode ser treinada com volumes muito maiores de dados que arquiteturas anteriores

Mecanismo de atenção

- Permite ao modelo decidir quais partes do texto são mais importantes em cada momento
- A cada token gerado, o modelo pondera todos os tokens anteriores
- Evita o problema de esquecimento das redes recorrentes em textos longos
- É o que dá ao Transformer sua capacidade de entender contexto amplo
- Tornou possível treinar modelos com janelas de contexto cada vez maiores

Ideia central

"O modelo dá mais peso às palavras que mais importam para entender a próxima."

Atenção é seletiva: nem todas as palavras pesam igual quando o modelo prevê a próxima.

M Ó D U L O

07

Dimensões

O conceito de espaço vetorial e como modelos representam significado

O que são dimensões em modelos de linguagem?

Definição

- Cada token é representado como um vetor com várias dimensões
- Dimensões são números que descrevem aspectos diferentes do significado
- Um modelo pode usar centenas ou milhares de dimensões por vetor
- Quanto mais dimensões, maior a capacidade de capturar nuances de significado
- Esses vetores são chamados de embeddings

Por que as dimensões importam?

Capturam significado

Permitem que o modelo represente sentido, contexto e relações entre palavras

Aproximam ideias semelhantes

Palavras com sentidos parecidos ficam próximas no espaço vetorial

Habilitam operações matemáticas

É possível medir similaridade calculando distância entre vetores

Influenciam o tamanho do modelo

Mais dimensões aumentam capacidade, mas também elevam custo computacional

Embeddings e espaço vetorial

Definição

- Embedding é a representação numérica de um token em um espaço de muitas dimensões
- Cada palavra, frase ou documento pode ser convertido em um vetor
- Modelos usam esses vetores para entender semelhança e relação entre conteúdos
- Operações entre vetores capturam relações semânticas, como sinônimos ou analogias
- Embeddings são fundamentais para busca semântica, recomendação e geração de respostas

Espaço vetorial



Conceitos relacionados ficam próximos

Recapitulando os conceitos da aula

- IA é o campo amplo que estuda sistemas com capacidades de inteligência humana
- ML aprende padrões a partir de dados; DL é ML com redes neurais profundas
- IA Generativa cria novos conteúdos a partir do que aprendeu
- Redes neurais são a base computacional do Deep Learning
- Modelo, algoritmo, treinamento e inferência formam o vocabulário essencial
- LLMs são grandes; SLMs são menores e mais especializados
- Transformers são a arquitetura por trás dos LLMs modernos
- Dimensões e embeddings permitem representar significado em vetores

P e r g u n t a 1

Uma organização criou um sistema de visão computacional para monitoramento de segurança em tempo real e lançou o produto no mercado. Qual é a etapa do processo de IA que é ativada quando o sistema analisa imagens capturadas pelas câmeras para reconhecer possíveis intrusos ou objetos suspeitos?

- (A) Treinamento
- (B) Inferência
- (C) Implantação do modelo
- (D) Correção de viés

P e r g u n t a 1

A Escola da Nuvem criou um sistema de visão computacional para monitoramento de segurança em tempo real e lançou o produto no mercado. Qual é a etapa do processo de IA que é ativada quando o sistema analisa imagens capturadas pelas câmeras para reconhecer possíveis intrusos ou objetos suspeitos?

- (A) Treinamento
- (B) Inferência**
- (C) Implantação do modelo
- (D) Correção de viés