

Embeddings, Dados e Aprendizado de Máquina



Agenda

01 Embeddings

Conceito, modelos de texto, imagem, multimodal e geração multimodal

02 Processamento de texto

Tokenização, bag-of-words, frequência, janela de contexto e intervalo

03 Tipos de dados

Dados estruturados versus dados não estruturados

04 Bancos de dados de vetores

Conceito e Aurora PostgreSQL com pgvector

05 Rotulagem de dados

Dados rotulados, SageMaker Ground Truth e Mechanical Turk

06 Tipos de aprendizado de máquina

Supervisionado, não supervisionado, reforço, federado e por transferência

M Ó D U L O

01

Embeddings

Como máquinas convertem palavras, imagens e conceitos em representações numéricas que podem ser comparadas, agrupadas e pesquisadas.

O que são embeddings

Definição

- Representação numérica de um dado em um espaço vetorial.
- Convertem texto, imagem ou áudio em vetores de números.
- Conceitos semelhantes ficam próximos no espaço vetorial.
- Conceitos diferentes ficam distantes uns dos outros.
- Permitem comparações por similaridade entre os dados.
- **Base de busca semântica, recomendação e RAG.**

ESPAÇO VETORIAL — VISÃO CONCEITUAL



Conceitos semelhantes formam vizinhanças.

Modelo de embedding de texto



Texto → Vetor

Definição

- Recebe palavras, frases ou documentos como entrada.
- Gera um vetor numérico que representa o significado do texto.
- Captura sinônimos, contexto e relações semânticas.
- Usado em busca semântica, classificação e clustering.
- Base de mecanismos de RAG (Retrieval-Augmented Generation).

EXEMPLO

"banco financeiro" → [0.21, -0.45, 0.88, 0.13, ...] (vetor com centenas de dimensões)

Modelo de embedding de imagem



Imagem → Vetor

Definição

- Recebe imagens como entrada (pixels, formas, cores).
- Gera um vetor que representa características visuais.
- Identifica padrões: objetos, texturas, composição.
- Permite buscar imagens similares por conteúdo visual.
- Aplicado em catálogos, moderação e visão computacional.

EXEMPLO



→ $[0.62, 0.05, -0.31, 0.74, \dots]$ (representa o conteúdo visual)

Modelo de embedding multimodal



Vários tipos
em um só espaço

Definição

- Processa diferentes tipos de dados (texto, imagem, áudio).
- Coloca todas as modalidades em um mesmo espaço vetorial.
- Permite comparar texto com imagem (e vice-versa).
- Base de buscas como “encontre a imagem que combine com este texto”.
- Útil para legendagem, busca cruzada e classificação multimodal.

EXEMPLO

texto "praia ao pôr do sol" e  → vetores próximos no mesmo espaço

Texto "praia ao pôr do sol" → $[0.81, 0.12, -0.44, 0.67, \dots]$

Foto de praia ao pôr do sol → $[0.79, 0.15, -0.41, 0.69, \dots]$

↑ Os números são parecidos!

Modelo de geração multimodal



Entrada de um tipo,
saída de outro

Definição

- Recebe uma modalidade e gera saída em outra modalidade.
- Texto pode virar imagem, áudio ou vídeo (e o inverso).
- Combina compreensão multimodal com geração de conteúdo.
- Aplicações: descrição de imagens, geração de imagens a partir de texto, legendagem automática.
- Não apenas representa: também produz novos conteúdos.

DIFERENÇA-CHAVE

Embedding multimodal compara conteúdos. Geração multimodal cria conteúdos novos.

Comparativo entre os modelos



Embedding de Texto

Converte palavras e frases em vetores de significado. Permite busca semântica e classificação.



Embedding de Imagem

Converte imagens em vetores de características visuais. Permite busca por similaridade visual.



Embedding Multimodal

Coloca texto e imagem no mesmo espaço. Permite comparar modalidades diferentes entre si.



Geração Multimodal

Cria saída em uma modalidade a partir de outra. Texto vira imagem, imagem vira descrição.

M Ó D U L O

02

Processamento de texto

Antes do embedding, o texto precisa ser quebrado, contado e organizado. Aqui estão os blocos básicos que sustentam qualquer modelo de linguagem.

Tokenização

Definição

- Processo de quebrar o texto em unidades menores chamadas tokens.
- Um token pode ser uma palavra, parte de palavra ou caractere.
- É a primeira etapa do processamento de linguagem natural.
- Permite que o modelo trabalhe com unidades padronizadas.
- A forma de tokenizar influencia diretamente o resultado do modelo.

EXEMPLO

"O gato dorme na cama"

↓ TOKENIZAÇÃO ↓



Cada peça é um token a ser convertido em vetor.

Bag-of-words

Definição

- Técnica clássica de representação de texto.
- Considera apenas quais palavras aparecem e quantas vezes.
- Ignora a ordem das palavras dentro do texto.
- Cada documento vira um vetor de contagens de palavras.
- Simples e útil, mas perde nuances de significado e contexto.

Texto: "o gato dorme na cama, o gato adora a casa"


Palavra	Frequência
gato	2
cama	1
dorme	1
casa	1

Contagem de frequência

Definição

- Mede quantas vezes cada palavra aparece em um texto ou conjunto.
- Palavras frequentes podem indicar o tema central do documento.
- Palavras raras podem ser muito informativas em buscas.
- Usada como base de bag-of-words e variações como TF-IDF.
- Ajuda a transformar texto em algo numérico e comparável.

FREQUÊNCIA POR PALAVRA



Janela de contexto

Definição

- Quantidade máxima de tokens que o modelo consegue ver de uma vez.
- Inclui tanto a entrada do usuário quanto a resposta do modelo.
- Janela maior permite analisar documentos mais longos.
- Janela maior também aumenta o custo de processamento.
- Limitar o contexto certo é decisão de arquitetura da solução.

JANELA DE CONTEXTO



entrada + saída cabem aqui dentro

Tokens excedentes são descartados ou truncados:



Pense na janela como o tamanho da memória de curto prazo do modelo.

Intervalo

Definição

- Recorte de texto com início e fim definidos dentro de um documento.
- Permite trabalhar com partes específicas, sem processar tudo.
- Útil quando o documento é maior do que a janela de contexto.
- Cada intervalo (chunk) pode ser indexado e buscado separadamente.
- Estratégia central em pipelines de RAG e busca semântica.

DOCUMENTO → INTERVALOS

Documento longo

Intervalo 1

Intervalo 2

Intervalo 3

M Ó D U L O

03

Tipos de dados

A natureza dos dados determina como eles devem ser armazenados, processados e consumidos por modelos de IA.

Estruturados vs não estruturados



DADOS ESTRUTURADOS

- Organizados em linhas e colunas (tabelas).
- Esquema fixo e bem definido.
- Fáceis de consultar com SQL.
- Exemplos: planilhas, bancos relacionais.
- Fáceis de validar e auditar.



DADOS NÃO ESTRUTURADOS

- Sem formato tabular pré-definido.
- Texto livre, imagens, áudio, vídeo, e-mails.
- Maioria dos dados gerados hoje no mundo.
- Difíceis de consultar com SQL tradicional.
- Exigem técnicas como embeddings para análise.

Por que isso importa para IA



Onde guardar

Estruturados vão para bancos relacionais. Não estruturados vão para data lakes e armazenamento de objetos.



Como buscar

Estruturados aceitam SQL. Não estruturados precisam de busca semântica via embeddings.



Como modelar

Modelos clássicos preferem dados estruturados. Modelos de IA generativa lidam bem com não estruturados.



Como processar

Pré-processamento e limpeza são mais simples no estruturado, mais sofisticados no não estruturado.

M Ó D U L O

04


Bancos de dados de vetores

Onde os embeddings são guardados, indexados e pesquisados em grande escala.

Bancos de dados de vetores

Definição

- Bancos especializados em armazenar embeddings.
- Indexam vetores para busca eficiente em grande volume.
- Permitem encontrar os vetores mais similares a uma consulta.
- Base de busca semântica, recomendação e RAG.
- Comparam vetores por proximidade no espaço vetorial.
- Diferem dos bancos relacionais clássicos no tipo de consulta.



Aurora PostgreSQL com pgvector

Definição

- Aurora PostgreSQL é o banco relacional gerenciado da AWS.
- A extensão pgvector adiciona suporte a tipos vetoriais.
- Permite armazenar embeddings em colunas do banco.
- Consulta vetores por similaridade usando SQL.
- Une dados estruturados e vetores no mesmo banco.
- Reduz a complexidade de manter um banco vetorial separado.



Aurora PostgreSQL

+ *extensão pgvector*

Banco relacional gerenciado da AWS, com suporte a vetores via pgvector.

M Ó D U L O

05

Rotulagem de dados

Modelos de IA aprendem com exemplos. Rotular esses exemplos é o que permite ensinar uma máquina a reconhecer padrões.

O que é rotulagem de dados

Definição

- Processo de marcar dados com a resposta correta.
- Cada exemplo recebe um rótulo (label) explicando o que é.
- Esses rótulos viram o material de ensino do modelo.
- Pode ser feito por humanos, máquinas ou de forma híbrida.
- Qualidade do rótulo influencia diretamente a qualidade do modelo.

EXEMPLO DE ROTULAGEM



rótulo: "gato"



rótulo: "cão"



rótulo: "carro"

Dados rotulados vs não rotulados



DADOS ROTULADOS

- Cada exemplo vem com sua resposta correta.
- Modelo aprende observando entrada e resposta esperada.
- Necessários para aprendizado supervisionado.
- Caros e demorados de produzir em grande volume.
- Geralmente exigem revisão humana.



DADOS NÃO ROTULADOS

- Apenas a entrada sem resposta associada.
- Mais abundantes e baratos de obter.
- Usados em aprendizado não supervisionado.
- Modelo precisa descobrir padrões por conta própria.
- Servem como base para muitos modelos pré-treinados.

Amazon SageMaker Ground Truth

Definição

- Serviço da AWS para rotulagem de dados em escala.
- Apoia rotulagem de imagens, texto, vídeo e mais.
- Combina trabalho humano com automação.
- Permite usar equipes próprias, fornecedores ou Mechanical Turk.
- Reduz tempo e custo da preparação de dados de treino.
- Foco em qualidade e governança do dataset rotulado.



SageMaker Ground Truth

Serviço gerenciado da AWS para construção de datasets rotulados com alta qualidade.

Amazon Mechanical Turk

Definição

- Plataforma da AWS de força de trabalho humana sob demanda.
- Trabalhadores executam tarefas que máquinas fazem mal.
- Útil para rotulagem, validação e curadoria de dados.
- Pode ser integrado ao SageMaker Ground Truth.
- Escala em paralelo: muitas pessoas trabalhando ao mesmo tempo.
- Modelo de pagamento por tarefa concluída.



Amazon Mechanical Turk

Plataforma de tarefas humanas em escala — chamadas de “human intelligence tasks”.

M Ó D U L O

06

Tipos de aprendizado de máquina

Como modelos aprendem a partir dos dados — supervisionado, não supervisionado, reforço, federado e por transferência.

Visão geral dos tipos de aprendizado



Supervisionado

Aprende com dados rotulados.



Não supervisionado

Encontra padrões em dados sem rótulo.



Por reforço

Aprende por tentativa e recompensa.



Federado

Treina sem centralizar os dados.



Por transferência

Reaproveita conhecimento prévio.

Aprendizado supervisionado



Aprende com
respostas certas

Definição

- Modelo aprende a partir de dados rotulados.
- Cada entrada tem uma resposta correta associada.
- Objetivo: prever a saída para entradas novas.
- Bom para classificação e regressão.
- Exige um conjunto rotulado de boa qualidade.
- Exemplos: detectar spam, prever preço, identificar imagens.

Aprendizado não supervisionado



Aprende a
organizar sozinho

Definição

- Modelo aprende a partir de dados não rotulados.
- Não recebe respostas certas descobre padrões sozinho.
- Útil para encontrar grupos (clustering) e estrutura escondida.
- Detecta anomalias e segmenta usuários ou produtos.
- Reduz dimensionalidade para visualização e simplificação.
- Aproveita o grande volume de dados sem rótulo.

Aprendizado por reforço



Aprende com
tentativa e erro

Definição

- Modelo (agente) interage com um ambiente.
- Toma ações e recebe recompensas ou penalidades.
- Aprende a estratégia que maximiza recompensas no longo prazo.
- Não precisa de dados rotulados previamente.
- Bom para tomada de decisão sequencial.
- Exemplos: jogos, robótica, otimização operacional.

Aprendizado federado



Treina sem
mover os dados

Definição

- Treinamento distribuído entre vários dispositivos ou organizações.
- Os dados permanecem onde foram gerados (não viajam).
- Cada participante treina localmente e envia apenas atualizações.
- Preserva privacidade e atende a requisitos regulatórios.
- Útil em saúde, finanças e dispositivos móveis.
- Combina conhecimento de várias fontes em um modelo central.

Aprendizado por transferência



Reaproveita o
que já foi aprendido

Definição

- Treinamento distribuído entre vários dispositivos ou organizações.
- Os dados permanecem onde foram gerados (não viajam).
- Cada participante treina localmente e envia apenas atualizações.
- Preserva privacidade e atende a requisitos regulatórios.
- Útil em saúde, finanças e dispositivos móveis.
- Combina conhecimento de várias fontes em um modelo central.

Quadro comparativo

Tipo	Dados usados	Como aprende	Onde se aplica
Supervisionado	Rotulados	Mapeia entrada → resposta	Classificação, regressão
Não supervisionado	Não rotulados	Descobre padrões sozinho	Clustering, anomalias
Por reforço	Interação com ambiente	Tentativa, erro e recompensa	Jogos, robótica, decisão
Federado	Distribuídos, locais	Treina sem centralizar dados	Privacidade e regulação
Por transferência	Modelo pré-treinado + ajuste	Reaproveita conhecimento	Modelos fundacionais, NLP

Síntese da aula



Embeddings

Conceitos viram vetores. Texto, imagem e multimodal vivem em espaços vetoriais comparáveis.



Processamento de texto

Tokenizar, contar, recortar base de todo modelo de linguagem.



Tipos de dados

Estruturados são tabulares e fáceis. Não estruturados dominam o mundo real.



Bancos de vetores

Aurora PostgreSQL com pgvector permite vetores e SQL no mesmo banco.



Rotulagem


Ground Truth e Mechanical Turk cuidam da preparação dos datasets.



Tipos de aprendizado

Cinco famílias: supervisionado, não supervisionado, reforço, federado e por transferência.

Como os conceitos se conectam



Todo pipeline de IA passa, em alguma forma, por essas etapas.

Recapitulando os conceitos da aula



Diferencie embedding e geração multimodal

Embedding compara conteúdos. Geração multimodal cria conteúdos novos a partir de outras modalidades.



Saiba escolher entre rotulado e não rotulado

Aprendizado supervisionado precisa de rótulos. Não supervisionado trabalha sem eles.



Lembre o papel do pgvector

Permite vetores em Aurora PostgreSQL um banco relacional gerenciado pela AWS.



SageMaker Ground Truth e Mechanical Turk

Ground Truth é o serviço gerenciado de rotulagem Mechanical Turk é a força de trabalho humana sob demanda.



Federado vs transferência

Federado distribui o treino para preservar privacidade. Transferência reaproveita modelos prévios.



Janela de contexto e intervalos

Janela define o quanto o modelo enxerga. Intervalos quebram documentos para caber na janela.

P e r g u n t a 1

Um instituto de pesquisa tem uma grande quantidade de dados genéticos não rotulados. O objetivo é identificar padrões e agrupamentos em diferentes perfis genéticos para desenvolver tratamentos personalizados. Qual metodologia de aprendizado de IA seria mais adequada para atender a esses requisitos?

- (A) Aprendizagem supervisionada
- (B) Aprendizagem não supervisionada
- (C) Aprendizagem por reforço a partir de feedback humano (RLHF)
- (D) Aprendizagem por reforço

P e r g u n t a 1

Um instituto de pesquisa tem uma grande quantidade de dados genéticos não rotulados. O objetivo é identificar padrões e agrupamentos em diferentes perfis genéticos para desenvolver tratamentos personalizados. Qual metodologia de aprendizado de IA seria mais adequada para atender a esses requisitos?

- (A) Aprendizagem supervisionada
- (B) Aprendizagem não supervisionada**
- (C) Aprendizagem por reforço a partir de feedback humano (RLHF)
- (D) Aprendizagem por reforço

P e r g u n t a 2

Uma plataforma educacional está desenvolvendo um assistente virtual para orientar os alunos durante seus estudos. A equipe quer que o assistente melhore suas recomendações ao longo do tempo, ajustando-se com base nos comentários e avaliações fornecidos pelos alunos após cada interação. Qual estratégia de aprendizado de IA seria a mais indicada para permitir essa melhoria contínua?

- (A) Aprendizado não supervisionado para identificar padrões de preferências de usuários
- (B) Aprendizado supervisionado com um conjunto de dados manualmente curado de avaliações positivas e negativas
- (C) Aprendizado supervisionado com um banco de dados de recomendações continuamente atualizado
- (D) Aprendizado por reforço com recompensas para feedback positivo dos usuários

P e r g u n t a 2

Uma plataforma educacional está desenvolvendo um assistente virtual para orientar os alunos durante seus estudos. A equipe quer que o assistente melhore suas recomendações ao longo do tempo, ajustando-se com base nos comentários e avaliações fornecidos pelos alunos após cada interação. Qual estratégia de aprendizado de IA seria a mais indicada para permitir essa melhoria contínua?

- (A) Aprendizado não supervisionado para identificar padrões de preferências de usuários
- (B) Aprendizado supervisionado com um conjunto de dados manualmente curado de avaliações positivas e negativas
- (C) Aprendizado supervisionado com um banco de dados de recomendações continuamente atualizado
- (D) Aprendizado por reforço com recompensas para feedback positivo dos usuários**

P e r g u n t a 3

Um laboratório de pesquisa quer evitar o custo e o tempo envolvidos na criação de modelos de aprendizado de máquina do zero e, em vez disso, deseja adaptar modelos já existentes para novas aplicações. Qual método de aprendizado de máquina atende melhor a essa necessidade?

- (A) Usar aprendizado por transferência
- (B) Usar aprendizado não supervisionado
- (C) Aumentar o número de épocas
- (D) Diminuir o número de épocas

P e r g u n t a 3

Um laboratório de pesquisa quer evitar o custo e o tempo envolvidos na criação de modelos de aprendizado de máquina do zero e, em vez disso, deseja adaptar modelos já existentes para novas aplicações. Qual método de aprendizado de máquina atende melhor a essa necessidade?

- (A) Usar aprendizado por transferência**
- (B) Usar aprendizado não supervisionado
- (C) Aumentar o número de épocas
- (D) Diminuir o número de épocas

P e r g u n t a 4

No Amazon BedRock, qual fator define a quantidade máxima de informações que podem ser enviadas em um único prompt?

- (A) Temperatura
- (B) Tamanho do lote
- (C) Janela de Contexto
- (D) Tamanho do modelo

P e r g u n t a 4

No Amazon BedRock, qual fator define a quantidade máxima de informações que podem ser enviadas em um único prompt?

- (A) Temperatura
- (B) Tamanho do lote
- (C) Janela de Contexto**
- (D) Tamanho do modelo

P e r g u n t a 5

Uma equipe de cientistas de dados está desenvolvendo um sistema de recomendação para uma plataforma de e-commerce. Esse sistema precisa analisar simultaneamente descrições textuais dos produtos e imagens dos mesmos para fornecer sugestões mais precisas aos usuários. Qual tipo de foundation model seria mais adequado para implementar esse sistema?

- (A) Modelo de incorporação de texto
- (B) Modelo de geração multimodal
- (C) Modelo de incorporação multimodal
- (D) Modelo de geração de imagens

P e r g u n t a 5

Uma equipe de cientistas de dados está desenvolvendo um sistema de recomendação para uma plataforma de e-commerce. Esse sistema precisa analisar simultaneamente descrições textuais dos produtos e imagens dos mesmos para fornecer sugestões mais precisas aos usuários. Qual tipo de foundation model seria mais adequado para implementar esse sistema?

- (A) Modelo de incorporação de texto
- (B) Modelo de geração multimodal
- (C) Modelo de incorporação multimodal**
- (D) Modelo de geração de imagens

P e r g u n t a 6

O que são tokens no contexto dos modelos de IA generativa?

- (A) Os tokens são as unidades básicas de entrada e saída com as quais um modelo de IA generativa opera, representando palavras, subpalavras ou outras unidades linguísticas
- (B) Os tokens são representações matemáticas de palavras ou conceitos usados em modelos de IA generativa
- (C) Os tokens são os prompts específicos ou instruções dadas ao modelo de IA generativa para gerar uma saída
- (D) Os tokens são os pesos pré-treinados de um modelo de IA generativa que são ajustados para tarefas específicas

P e r g u n t a 6

O que são tokens no contexto dos modelos de IA generativa?

- (A) Os tokens são as unidades básicas de entrada e saída com as quais um modelo de IA generativa opera, representando palavras, subpalavras ou outras unidades linguísticas**
- (B) Os tokens são representações matemáticas de palavras ou conceitos usados em modelos de IA generativa
- (C) Os tokens são os prompts específicos ou instruções dadas ao modelo de IA generativa para gerar uma saída
- (D) Os tokens são os pesos pré-treinados de um modelo de IA generativa que são ajustados para tarefas específicas