



# Técnicas de Machine Learning

• Regressão • Classificação • Clustering

# Agenda

## 01 Fundamentos de Machine Learning

Conceito, contexto na nuvem e as três famílias de técnicas

## 02 Regressão

Regressão Linear e Árvores de Decisão

## 03 Classificação

Binária, Limiar (Intervalo), Multiclasse, K-NN, XGBoost

## 04 Clustering

Aprendizado não-supervisionado e K-means

M Ó D U L O

# 01

## Fundamentos de Machine Learning

Conceito

# O que é Machine Learning?

## Definição

### Aprendizado a partir de dados

Em vez de programar regras explícitas, o computador identifica padrões nos dados e aprende a tomar decisões.

### Por que isso importa?

Permite resolver problemas onde escrever regras manualmente seria inviável: prever valores, classificar itens, agrupar perfis, recomendar conteúdo.

#### Fluxo conceitual

Dados históricos (entrada)



Modelo de ML (aprendizado)



Previsão / Decisão (saída)

# Machine Learning no contexto da nuvem



## Escala sob demanda

A nuvem fornece recursos computacionais elásticos para treinar e executar modelos de ML.



## Serviços gerenciados

Provedores oferecem ferramentas que simplificam o ciclo de vida dos modelos, do treino à produção.



## Acesso democratizado

Profissionais não-cientistas-de-dados conseguem aplicar ML usando APIs e serviços prontos.

# As três grandes famílias de técnicas

01

## Regressão

*Pergunta: Quanto?*

Prever um valor numérico contínuo (preço, temperatura, demanda).

• *Regressão Linear* • *Árvores de Decisão*

02

## Classificação

*Pergunta: Qual categoria?*

Atribuir uma classe ou rótulo a uma observação.

• *Binária* • *Multiclasse* • *K-NN* • *XGBoost*

03

## Clustering

*Pergunta: Quem se parece com quem?*

Encontrar grupos naturais sem rótulos predefinidos.

• *K-means*

M Ó D U L O

# 02

## Regressão

Prever valores numéricos contínuos

- Regressão Linear
- Árvores de Decisão

# O que é Regressão?

## Objetivo central

Prever um número, uma quantidade ou uma medida contínua.

## Características

- A saída é numérica, e não uma categoria.
- O modelo aprende a relação entre variáveis de entrada e a variável-alvo.
- Avaliação considera o quão próxima a previsão está do valor real.



## Exemplos típicos

- Preço de um imóvel a partir de área e localização
- Demanda futura de um produto no varejo
- Tempo estimado de entrega de um pedido
- Consumo de energia em uma região



# Regressão Linear

## Ideia central


Traçar a melhor linha reta que descreve a relação entre uma variável de entrada e o valor a prever.

## Como funciona

- O modelo busca a reta que minimiza o erro entre as previsões e os valores reais.
- Cada variável recebe um peso, indicando seu impacto na previsão.
- A previsão final é uma combinação linear dessas variáveis.

## Vantagens e limites

- Simples, rápida e fácil de interpretar.
- Funciona bem quando a relação entre as variáveis é aproximadamente linear.



# Intuição: a reta que melhor descreve os dados



## Encontrar o padrão

Observar como a variável-alvo cresce ou decresce conforme a entrada.



## Traçar a reta

Escolher a reta que passa o mais próximo possível de todos os pontos.



## Usar para prever

Para um novo valor de entrada, ler na reta o valor numérico esperado.



## Caso prático: prever o preço de imóveis

- Entrada: área do imóvel em metros quadrados.
- Saída prevista: preço estimado do imóvel.
- A reta aprendida resume: quanto cada metro quadrado adiciona, em média, ao valor.

# Árvores de Decisão

## Ideia central


Tomar decisões sucessivas em forma de perguntas, dividindo os dados em grupos cada vez mais homogêneos.

## Estrutura da árvore

- Cada nó interno representa uma pergunta sobre uma variável.
- Cada ramo representa uma resposta possível.
- Cada folha entrega uma previsão final (um valor numérico, no caso da regressão).

## Por que é útil

- Captura relações não-lineares e regras condicionais.
- Resultado fácil de interpretar visualmente.



# Regressão Linear vs Árvores de Decisão



## Regressão Linear

- Captura relações lineares.
- Coeficientes fáceis de interpretar.
- Treinamento rápido e estável.
- Menos eficaz quando os dados têm padrões complexos ou condicionais.



## Árvores de Decisão

- Captura relações não-lineares e por regras.
- Decisões em forma de árvore, fáceis de visualizar.
- Lida bem com diferentes tipos de variáveis.
- Pode se ajustar demais aos dados se for muito profunda.

M Ó D U L O

# 03

## Classificação

Atribuir uma categoria a cada observação

- Binária
- Limiar (Intervalo)
- Multiclasse
- K-NN
- XGBoost

# O que é Classificação?

## Objetivo central

Atribuir um rótulo (uma categoria) a cada observação, com base em padrões aprendidos a partir de exemplos rotulados.

## Diferença em relação à regressão

- Regressão prevê números; classificação prevê categorias.

## Tipos principais

- Classificação Binária — apenas duas classes possíveis.
- Classificação Multiclasse — três ou mais classes possíveis.



## Exemplos típicos

- Detectar se um e-mail é spam ou não (binária)
- Aprovar ou negar uma transação como fraude
- Identificar o tipo de produto em uma imagem (multiclasse)
- Classificar o sentimento de um comentário

# Classificação Binária

## Definição

O modelo precisa escolher entre apenas duas categorias possíveis.


## Como o modelo decide

- Calcula a probabilidade de a observação pertencer à classe positiva.
- Compara essa probabilidade com um limiar de decisão.
- Acima do limiar: classe positiva. Abaixo: classe negativa.

## Exemplos práticos

- Fraude / Não-fraude.
- Spam / Não-spam.
- Cliente irá cancelar? Sim ou não.

## Duas classes possíveis



Decisão final = **uma e somente uma das duas opções.**

*O modelo aprende a fronteira que separa as duas classes.*

# Intervalo: o limiar de decisão

## O que é limiar (intervalo)

É o valor de probabilidade a partir do qual o modelo escolhe uma classe em vez da outra.

## Por que ajustar esse intervalo

- Limiar mais baixo: o modelo aceita mais casos como positivos (mais sensível).
- Limiar mais alto: o modelo aceita menos casos como positivos (mais conservador).

## Trade-off envolvido

- Aumentar a sensibilidade pode gerar mais alarmes falsos.
- Aumentar o rigor pode deixar passar casos importantes.





# Classificação Multiclasse

## Definição

O modelo escolhe entre três ou mais categorias possíveis para cada observação.


## Como o modelo decide

- Calcula a probabilidade de cada classe possível.
- Atribui a observação à classe com maior probabilidade.

## Exemplos práticos

- Categorizar tickets de suporte: financeiro, técnico, comercial.
- Identificar o idioma de um texto.
- Reconhecer o tipo de objeto em uma imagem.

### Probabilidade por classe



*O modelo escolhe a classe com maior probabilidade.*

# K-NN (K-Nearest Neighbors)

## Ideia central

Para classificar uma nova observação, o modelo olha quais são os K vizinhos mais próximos no conjunto de exemplos conhecidos.


## Como funciona

- Calcula a distância entre o novo ponto e os pontos já rotulados.
- Seleciona os K pontos mais próximos.
- Atribui ao novo ponto a classe mais frequente entre esses vizinhos.

## Características

- Algoritmo simples e intuitivo.
- Não exige treinamento prévio elaborado.
- Pode ficar lento com volumes grandes de dados.

Quem está mais perto do novo ponto?



● Classe A      ● Classe B      ● Novo ponto

# A escolha do K importa

01

## K muito pequeno

O modelo se torna sensível a ruído: pequenas variações nos vizinhos podem mudar a decisão.

02

## K muito grande

O modelo perde sensibilidade local e tende a sempre prever a classe majoritária.

03

## K bem ajustado

Equilíbrio entre captar a vizinhança imediata e ignorar pontos isolados que não representam o padrão.

# XGBoost

## Ideia central

Combinar várias árvores de decisão simples, em sequência, para construir um modelo final mais forte.


## Como funciona

- Treina uma árvore inicial e observa onde ela erra.
- A próxima árvore foca em corrigir esses erros.
- O processo se repete, somando o conhecimento de várias árvores.

## Por que é tão usado

- Alta precisão em problemas tabulares.
- Lida bem com diferentes tipos de variáveis.
- Bom desempenho mesmo com volumes consideráveis de dados.

### Aprendizado em sequência



**Cada nova árvore é treinada para corrigir os erros das anteriores.**

O modelo final combina o conhecimento de todas elas.

# Por que é referência em problemas de classificação



## Aprendizado por correção

Cada árvore foca exatamente nos erros cometidos pelas anteriores.



## Modelo final mais robusto

A combinação das árvores produz uma decisão mais estável e precisa.



## Versátil

Funciona tanto em classificação binária quanto multiclasse e também em regressão.



## Padrão de mercado

Muito usado em competições de ciência de dados e em soluções de produção.

# Ranking — aprendendo a ordenar

## Ideia central

Em vez de prever uma classe ou um valor, o modelo aprende a ordenar itens por relevância dentro de um grupo.

## Como aprende

Durante o treino, o XGBoost compara pares de itens do mesmo grupo. O item mais relevante deve receber pontuação maior e o modelo é ajustado para que isso aconteça.

## Onde se aplica

Buscadores, sistemas de recomendação, ranking de produtos em e-commerce e priorização de leads em CRMs.

### Ordenação por relevância

Busca: “tênis para corrida”

|    |                  |                        |     |
|----|------------------|------------------------|-----|
| #1 | Tênis de corrida | <div><div></div></div> | 9.2 |
| #2 | Tênis esportivo  | <div><div></div></div> | 7.5 |
| #3 | Tênis casual     | <div><div></div></div> | 5.1 |
| #4 | Sandália         | <div><div></div></div> | 2.3 |

O modelo aprende a colocar os itens mais relevantes no topo.

M Ó D U L O

# 04

## Clustering

Encontrar grupos naturais nos dados

K-means

# O que é Clustering?

## Objetivo central

Agrupar observações que se parecem, sem dispor de rótulos previamente definidos.

## Diferença em relação às técnicas anteriores

- Não há um valor-alvo para o modelo aprender a prever.
- O algoritmo descobre, sozinho, quais observações pertencem ao mesmo grupo.

## Pergunta que responde

*Quem se parece com quem dentro deste conjunto de dados?*



## Aplicações típicas

- Segmentar clientes por comportamento de compra
- Agrupar usuários com perfis de uso semelhantes
- Identificar grupos de produtos com características parecidas
- Detectar padrões anômalos em logs ou tráfego



# K-means

## Ideia central

Dividir os dados em K grupos, de forma que pontos dentro do mesmo grupo sejam parecidos entre si e diferentes dos demais grupos.


## Conceito de centróide

- Cada grupo é representado por um ponto central, chamado centróide.
- Cada observação é atribuída ao centróide mais próximo.

## O papel do K

- K define quantos grupos o algoritmo deve formar.
- É uma escolha do analista e influencia diretamente o resultado.

### Três grupos descobertos automaticamente



*x = centróide do grupo*

# Como o algoritmo funciona

01

## Definir K

O analista escolhe quantos grupos o algoritmo deve formar.

02

## Posições iniciais

K centróides são posicionados, inicialmente, em locais quaisquer dos dados.

03

## Atribuir pontos

Cada observação é associada ao centróide mais próximo, formando um grupo.

04

## Atualizar centróides

Cada centróide é recalculado para representar o centro do seu grupo atual.

05

## Repetir até estabilizar

Os passos 3 e 4 se repetem até que os grupos não mudem mais.

# Aplicações e cuidados



## Aplicações típicas

- Segmentação de clientes em perfis comportamentais.
- Agrupamento de produtos por características.
- Identificação de regiões com padrões similares.
- Análise exploratória inicial de grandes volumes de dados.



## Pontos de atenção

- A escolha do K influencia muito o resultado.
- Funciona melhor com grupos de formato regular.
- É sensível à escala das variáveis (preparação dos dados é importante).
- Os grupos descobertos precisam ser interpretados pelo analista.

# Visão comparativa das técnicas

| Família       | Saída prevista          | Tipo de aprendizado | Técnicas vistas                      |
|---------------|-------------------------|---------------------|--------------------------------------|
| Regressão     | Valor numérico contínuo | Supervisionado      | Regressão Linear, Árvores de Decisão |
| Classificação | Categoria (rótulo)      | Supervisionado      | Binária, Multiclasse, K-NN, XGBoost  |
| Clustering    | Grupo descoberto        | Não-supervisionado  | K-means                              |

# Como escolher a técnica adequada

**Preciso prever um valor numérico?**

*Use Regressão.*

Linear (relação simples) ou Árvores (relações condicionais).

**Preciso atribuir uma categoria?**

*Use Classificação.*

K-NN (problema simples) ou XGBoost (alta precisão em dados tabulares).

**Não tenho rótulos e quero descobrir grupos?**

*Use Clustering.*

K-means para encontrar segmentos naturais nos dados.

# Principais aprendizados da aula

1

## **ML é aprendido a partir de dados**

Em vez de regras, padrões. A nuvem oferece a infraestrutura para isso em escala.

2

## **Três famílias resolvem três perguntas distintas**

Quanto? (Regressão), qual categoria? (Classificação), quem se parece com quem? (Clustering).

3

## **A escolha da técnica depende do problema**

Tipo da saída desejada, presença ou não de rótulos e complexidade dos padrões nos dados.

4

## **Conceitos antes de ferramentas**

Compreender o raciocínio das técnicas é a base para usar bem qualquer serviço de ML em nuvem.