

Tipos de Inferência e Métricas de Performance de Modelos

Fundamentos conceituais para arquitetos e profissionais de nuvem

Agenda

01

Tipos de Inferência

Inferência em lote (batch), Inferência em tempo real
Comparação entre as abordagens, Inferência assíncrona, Inferência serverless e SageMaker
Serverless Inference

02

Métricas de Performance

Acurácia, Precisão, Recall, F1 Score e AUC
Matriz de confusão, MAE (Mean Absolute Error)
E Métricas de negócio (ROI, custo, impacto)

M Ó D U L O

01

Tipos de Inferência

- Inferência em lote (batch)
- Inferência em tempo real
- Comparação entre as abordagens
- Inferência assíncrona
- Inferência serverless
- SageMaker Serverless Inference

Tipos de Inferência: visão geral

Definição

- Inferência é o uso do modelo já treinado para gerar previsões a partir de novos dados.
- Diferentes contextos de uso exigem diferentes formas de servir o modelo.
- A escolha do tipo de inferência impacta latência, custo e arquitetura.
- Principais abordagens: lote, tempo real, assíncrona e serverless.

Lote

Grandes volumes
processados juntos

Tempo real

Resposta imediata por
requisição

Assíncrona

Processada em segundo
plano

Serverless

Sem gerenciar servidores

Inferência em Lote (Batch)

Definição


- Processa grandes volumes de dados de uma só vez.
- Execução planejada não exige resposta imediata.
- Resultados são gravados em armazenamento (ex.: arquivo, banco).
- Recursos computacionais são alocados apenas durante o job.
- Geralmente apresenta menor custo por previsão.



Inferência em Tempo Real

Definição

- Resposta imediata a cada requisição (latência em milissegundos).
- Endpoint do modelo permanece sempre disponível.
- Capacidade dimensionada para o pico de uso esperado.
- Custo geralmente maior, pela disponibilidade contínua.
- Exige monitoramento próximo de latência e disponibilidade.



Inferência em Lote vs Tempo Real


Critério	Inferência em Lote	Inferência em Tempo Real
Latência	Alta - minutos a horas	Baixa - milissegundos
Volume	Grandes volumes acumulados	Requisições individuais
Custo	Menor - recursos sob demanda	Maior - endpoint sempre ativo
Disponibilidade	Job executado periodicamente	Endpoint contínuo
Uso típico	Relatórios, scoring noturno	Apps interativos, fraude online

Inferência Assíncrona

Como funciona

- A requisição é enviada e o processamento ocorre em segundo plano.
- O resultado é entregue quando a previsão estiver pronta (sem bloqueio).
- Útil quando o tempo de inferência é longo ou o payload é grande.
- Posiciona-se entre o lote e o tempo real, equilibrando latência e custo.
- Permite processar requisições mesmo sem resposta imediata ao cliente.

Indicada quando o cliente pode esperar, mas o volume não justifica um lote agendado.



Inferência Serverless

Definição

- O usuário não gerencia servidores nem capacidade do endpoint.
- A infraestrutura escala automaticamente conforme a demanda.
- Cobrança somente pelo uso efetivo da inferência.
- Adequado para cargas intermitentes, imprevisíveis ou com baixa frequência.
- Reduz a complexidade operacional e o custo ocioso.



SageMaker Serverless Inference

Características principais

- Serviço gerenciado da AWS para servir modelos sem provisionar infraestrutura.
- Inicialização automática do endpoint quando há requisições.
- Sem custo enquanto o endpoint está ocioso.
- Escala automaticamente conforme o tráfego varia.
- Indicado para workloads imprevisíveis ou de baixo volume.

 **Endpoint sob demanda**
Existe apenas quando há requisições — paga por uso real

SAGEMAKER

Disponibilidade do endpoint ao longo do tempo
Cada barra representa o endpoint ativo (cobrando)

REAL-TIME
Sempre ativo
Instância dedicada 24/7

endpoint ligado o tempo todo

custo: cobra por hora de instância (ligada ou ociosa)

SERVERLESS
Sob demanda
ativa só quando há request

custo: cobra apenas pelo tempo de inferência ativa

QUANDO USAR


CENÁRIO 01
POC e protótipos
Validação de modelos sem comprometer infraestrutura.


CENÁRIO 02
Tráfego intermitente
Apps com uso esporádico ou em horários específicos.


CENÁRIO 03
Baixo volume
Quando manter uma instância ligada não compensa.

ATENÇÃO
Pode ocorrer **cold start** na primeira requisição — não ideal se latência consistente for crítica.

M Ó D U L O

02

Métricas de Performance de Modelos

Acurácia

Precisão

Recall

F1 Score

AUC

Matriz de confusão

MAE (Mean Absolute Error)

Métricas de negócio (ROI, custo, impacto)

Métricas de Performance de Modelos

Características principais

- Um modelo precisa ser avaliado antes de ir para produção.
- Cada métrica responde a uma pergunta diferente sobre o desempenho.
- A escolha da métrica depende do tipo de problema e do impacto do erro.
- Métricas técnicas devem ser combinadas com métricas de negócio.

 **Mapa das métricas** MÓDULO 02
Cada categoria responde a uma pergunta diferente

 **CATEGORIA 1**
Classificação
Pergunta: o modelo acertou a classe correta?
Acurácia Precisão Recall F1 Score AUC + Matriz de confusão

 **CATEGORIA 2**
Regressão
Pergunta: o quanto a previsão se afasta do valor real?
MAE + outras métricas de erro

 **CATEGORIA 3**
Negócio
Pergunta: o modelo gera valor para a organização?
ROI Custo Impacto

Métricas técnicas precisam ser combinadas com métricas de negócio

Matriz de Confusão

Características principais

- Estrutura que organiza acertos e erros em problemas de classificação.
- É a base de várias métricas (acurácia, precisão, recall, F1).
- Permite enxergar onde o modelo erra, e não apenas o quanto erra.

		Previsto	
		Positivo	Negativo
Real	Pos.	VP Verdadeiro Positivo	FP Falso Positivo
	Neg.	FN Falso Negativo	VN Verdadeiro Negativo

Acurácia

Características principais

- Proporção de previsões corretas em relação ao total.
- Fórmula conceitual: $(\text{acertos}) \div (\text{total de previsões})$.
- Boa visão geral quando as classes estão balanceadas.
- Pode ser enganosa em problemas com classes desbalanceadas.

Fórmula

$$\frac{(VP + VN)}{VP + VN + FP + FN}$$

Atenção em classes desbalanceadas.

Precisão

Características principais

- Dos exemplos previstos como positivos, quantos eram realmente positivos.
- Fórmula conceitual: $VP \div (VP + FP)$.
- Importante quando o custo de um falso positivo é alto.
- Exemplo: marcar uma transação legítima como fraude.

Fórmula

$$\frac{VP}{VP + FP}$$

Foco: reduzir falsos positivos.

Recall (Sensibilidade)

Características principais

- Dos exemplos realmente positivos, quantos o modelo conseguiu identificar.
- Fórmula conceitual: $VP \div (VP + FN)$.
- Importante quando o custo de um falso negativo é alto.
- Exemplo: deixar passar um caso real de fraude ou de doença.

Fórmula


$$\frac{VP}{VP + FN}$$

Foco: reduzir falsos negativos.

F1 Score

Características principais

- Combina Precisão e Recall em uma única métrica.
- É a média harmônica entre as duas penaliza desequilíbrios.
- Útil quando se deseja equilíbrio entre falsos positivos e falsos negativos.
- Especialmente recomendado em problemas com classes desbalanceadas.



AUC - Area Under the Curve

Características principais

- Mede a capacidade do modelo em distinguir entre as classes.
- Avalia o desempenho considerando diferentes limiares de decisão.
- Valores próximos de 1 indicam ótima separação entre classes.
- Valores próximos de 0,5 indicam desempenho semelhante ao acaso.
- Independente do limiar específico de classificação utilizado.

INTERPRETAÇÃO

■ 0,90 — 1,00	Excelente
■ 0,80 — 0,90	Bom
■ 0,70 — 0,80	Razoável
■ 0,50 — 0,70	Fraco
■ $\approx 0,50$	Aleatório

MAE - Mean Absolute Error

Características principais

- Métrica usada em problemas de regressão (saída numérica contínua).
- Calcula o erro absoluto médio entre o valor previsto e o valor real.
- Mantém a mesma unidade da variável que está sendo prevista.
- Quanto menor o MAE, mais próximo o modelo está dos valores reais.
- Interpretação direta e fácil de comunicar para áreas de negócio.

EM UMA FRASE

"Em média, o quanto a previsão se afasta do valor real."

Aplicações: previsão de demanda, preço, temperatura, tempo.

Métricas de Negócio

Por que olhar além das métricas técnicas?

Um modelo tecnicamente bom precisa também gerar valor para a organização.

ROI

Retorno sobre investimento

Compara o ganho gerado pelo modelo com o custo de desenvolvê-lo e operá-lo.

Custo

Operação e infraestrutura

Considera o custo de inferência, treinamento, armazenamento e manutenção.

Impacto

Efeito real no negócio

Mede mudança em indicadores como receita, conversão, churn ou eficiência.

Resumo da aula

- O tipo de inferência (lote, tempo real, assíncrona, serverless) deve ser escolhido pelo caso de uso, não pela tecnologia.
- Cada métrica de classificação responde a uma pergunta diferente analise sempre matriz de confusão e o impacto dos erros.
- MAE é a métrica de erro mais direta para problemas de regressão.
- Métricas técnicas isoladas não bastam: ROI, custo e impacto definem se o modelo realmente entrega valor.



O que levar para casa

Os 4 pontos centrais da aula

RESUMO

01

TIPO DE INFERÊNCIA

Escolha pelo caso de uso

Lote, tempo real, assíncrona ou serverless — não pela tecnologia.



02

CLASSIFICAÇÃO

Cada métrica tem seu papel

Analise sempre a matriz de confusão e o impacto dos erros no problema.



03

REGRESSÃO

MAE é a mais direta de comunicar

Mantém a unidade da variável prevista e responde "o quanto a previsão erra em média?".



04

VALOR REAL

Métricas técnicas não bastam

ROI, custo e impacto definem se o modelo realmente entrega valor.



Bom modelo é o que combina técnica e impacto no negócio

P e r g u n t a 1

Uma organização de saúde está desenvolvendo um modelo de aprendizado de máquina (ML) para analisar dados de históricos médicos arquivados. A organização precisa realizar inferência em grandes conjuntos de dados que possuem vários GB de tamanho. A organização não precisa acessar as previsões do modelo imediatamente. Qual opção de inferência do Amazon SageMaker atenderá a esses requisitos?

- (A) Inferência em tempo real
- (B) Inferência assíncrona
- (C) Transformação em lote
- (D) Inferência sem servidor

P e r g u n t a 1

Uma organização de saúde está desenvolvendo um modelo de aprendizado de máquina (ML) para analisar dados de históricos médicos arquivados. A organização precisa realizar inferência em grandes conjuntos de dados que possuem vários GB de tamanho. A organização não precisa acessar as previsões do modelo imediatamente. Qual opção de inferência do Amazon SageMaker atenderá a esses requisitos?

- (A) Inferência em tempo real
- (B) Inferência assíncrona
- (C) Transformação em lote**
- (D) Inferência sem servidor

P e r g u n t a 2

Uma organização utiliza o Amazon SageMaker para processar modelos de Machine Learning (ML) em um ambiente de aprendizado online. A instituição lida com grandes volumes de dados dos alunos, com arquivos de até 1 GB e tempos de processamento de aproximadamente 1 hora. Ela precisa de uma solução de inferência que forneça resultados quase em tempo real para garantir um feedback rápido aos alunos. Qual opção de inferência do SageMaker atende a esses requisitos?

- (A) Transformação em lote
- (B) Inferência em tempo real
- (C) Inferência assíncrona
- (D) Inferência sem servidor

P e r g u n t a 2

Uma organização utiliza o Amazon SageMaker para processar modelos de Machine Learning (ML) em um ambiente de aprendizado online. A instituição lida com grandes volumes de dados dos alunos, com arquivos de até 1 GB e tempos de processamento de aproximadamente 1 hora. Ela precisa de uma solução de inferência que forneça resultados quase em tempo real para garantir um feedback rápido aos alunos. Qual opção de inferência do SageMaker atende a esses requisitos?

- (A) Transformação em lote
- (B) Inferência em tempo real
- (C) Inferência assíncrona**
- (D) Inferência sem servidor