

# Avaliação de Modelos de IA: Infraestrutura de Treinamento e Inferência na AWS

*MSE · RMSE ·  $R^2$  · PDPs · EC2 Trainium (Trn) · EC2 Inferentia (Inf)*

# Agenda

## 01 Por que avaliar um modelo de IA?

Contexto e motivação para o uso de métricas.

## 03 RMSE — Root Mean Squared Error

Relação com o MSE e ganho de interpretabilidade.

## 05 PDPs — Partial Dependence Plots

Explicabilidade: entendendo o efeito das variáveis.

## 02 MSE — Mean Squared Error

Conceito, fórmula e características da métrica.

## 04 $R^2$ — Coeficiente de Determinação

Quanto da variância o modelo explica.

## 06 EC2 Trainium e Inferentia

Infraestrutura AWS para treinar e inferir.

M Ó D U L O

# 01

## Por que avaliar um modelo de IA?

Contexto e motivação para o uso de métricas em IA.

# Por que avaliar um modelo de IA?

## Definição

- Modelo treinado não significa modelo confiável
- Precisamos medir o quanto o modelo erra e o quanto acerta
- Métricas tornam a qualidade do modelo objetiva e comparável
- Permitem comparar diferentes algoritmos sobre os mesmos dados
- Apoiam decisões de negócio baseadas em evidências numéricas



*Métricas são o vocabulário comum entre quem treina o modelo e quem decide pelo negócio.*

# O conceito de erro em modelos preditivos

## Definição

- Em modelos de regressão, o modelo prevê um valor numérico
- Erro é a diferença entre o valor previsto e o valor real
- Cada previsão gera um erro individual (positivo ou negativo)
- O conjunto dos erros precisa ser resumido em uma única métrica
- MSE, RMSE e  $R^2$  são formas diferentes de resumir esses erros



$$\text{Erro} = \text{Previsto} - \text{Real}$$

*Resumir o conjunto  
de erros é o papel  
das métricas*

M Ó D U L O

# 02

## MSE — Mean Squared Error

Conceito, fórmula e características da métrica.

# Mean Squared Error — Erro Quadrático Médio

## Definição

- Em modelos de regressão, o modelo prevê um valor numérico
- Erro é a diferença entre o valor previsto e o valor real
- Cada previsão gera um erro individual (positivo ou negativo)
- O conjunto dos erros precisa ser resumido em uma única métrica
- MSE, RMSE e  $R^2$  são formas diferentes de resumir esses erros



$$\text{MSE} = \text{média dos } ( \text{valor previsto} - \text{valor real} )^2$$

# O que esperar dessa métrica



## Sempre positivo

O quadrado elimina sinais, quanto menor, melhor o modelo.



## Sensível a outliers

Erros grandes ganham peso desproporcional ao serem elevados ao quadrado.



## Unidade ao quadrado

O resultado não está na mesma unidade da variável original.



## Comparações entre modelos

Ideal para comparar modelos avaliados no mesmo conjunto de dados.



M Ó D U L O

# 03

## RMSE — Root Mean Squared Error

Relação com o MSE e ganho de interpretabilidade.

# Root Mean Squared Error — Raiz do Erro Quadrático Médio

## Definição

- Derivada diretamente do MSE
- É simplesmente a raiz quadrada do MSE
- Volta o resultado para a unidade original dos dados
- Mais fácil de interpretar do que o MSE puro
- Também penaliza erros grandes, mas em escala interpretável

$$\text{RMSE} = \text{raiz quadrada de ( MSE )}$$

# Como ler o valor do RMSE

## Definição

- Pode ser lido como o erro médio típico do modelo
- Está na mesma unidade da variável que se quer prever
- Ex.: prevendo preço em reais, o RMSE também está em reais
- Quanto menor o RMSE, mais próximo o modelo está dos valores reais
- Continua sensível a outliers, herdando essa propriedade do MSE

## LEITURA INTUITIVA

*"Em média, o modelo erra cerca de X unidades em relação ao valor real."*

## MSE vs. RMSE

### MSE

- Erros elevados ao quadrado
- Unidade ao quadrado (não interpretável)
- Penaliza fortemente erros grandes
- Útil em otimização matemática

### RMSE

- Raiz quadrada do MSE
- Mesma unidade dos dados originais
- Mais intuitivo para comunicação
- Preferido em relatórios e apresentações

*MSE e RMSE contam a mesma história — o RMSE apenas a conta na unidade dos dados.*

M Ó D U L O

# 04

## $R^2$ — Coeficiente de Determinação

Quanto da variância o modelo explica.

## Como ler o valor do RMSE

### Definição

- Métrica que mede a qualidade do ajuste de um modelo
- Indica quanto da variância dos dados é explicada pelo modelo
- Não mede o erro em si, mas o poder explicativo
- Costuma ser apresentada em escala de 0 a 1 (ou em porcentagem)
- Complementa o MSE/RMSE com uma visão proporcional



***$R^2$  = fração da variabilidade dos dados que o modelo consegue explicar***

## Como ler o valor do R-squared

1

### Modelo perfeito

Explica toda a variabilidade dos dados.

0

### Não explica nada

Equivale a prever sempre a média dos valores reais.

< 0

### Pior que a média

Modelo é menos útil do que simplesmente usar a média.

- Quanto mais próximo de 1, mais o modelo se aproxima dos dados reais
- Valores intermediários indicam que parte da variação não é explicada

## Cuidados ao usar o $R^2$

### Definição

- $R^2$  alto não garante que o modelo seja bom em produção
- Pode ser inflado artificialmente ao adicionar muitas variáveis
- Não substitui o MSE/RMSE fornece uma visão complementar
- Avalia apenas o ajuste, não avalia generalização
- Deve ser analisado sempre junto de outras métricas e validações



*Boa prática: combinar  $R^2$  com RMSE para avaliar tanto a qualidade do ajuste quanto a magnitude do erro.*



# MSE, RMSE e R² lado a lado

| Métrica | O que mede                      | Unidade              | Sensível a outliers? | Ideal para                |
|---------|---------------------------------|----------------------|----------------------|---------------------------|
| MSE     | Média do erro ao quadrado       | Ao quadrado          | Sim                  | Otimização do modelo      |
| RMSE    | Raiz do MSE                     | Mesma da variável    | Sim                  | Comunicação do erro       |
| R²      | Variância explicada pelo modelo | Adimensional (0 a 1) | Indiretamente        | Avaliar poder explicativo |



Boa prática profissional: relatar sempre RMSE e R² em conjunto para uma avaliação equilibrada.

M Ó D U L O

# 05

## PDPs — Partial Dependence Plots

Métricas dizem o quanto o modelo erra.  
PDPs ajudam a entender o porquê.

# Partial Dependence Plots — Gráficos de Dependência Parcial

## Definição

- Ferramenta de explicabilidade de modelos de IA
- Mostram a relação entre uma variável e as previsões do modelo
- Ajudam a responder: "como esta variável influencia a previsão?"
- Aplicáveis a modelos complexos, inclusive caixa-preta
- Apresentadas em forma de gráfico, fáceis de comunicar

***PDP responde: "em média, o que acontece com a previsão quando esta variável muda?"***

## A ideia conceitual por trás do gráfico

1

### Escolher uma variável

Selecionamos uma feature de interesse para analisar.

2

### Variar seus valores

Geramos previsões para diferentes valores dessa variável, mantendo as demais.

3

### Plotar a média


Calculamos a média das previsões e desenhamos a curva resultante.

*Resultado: uma curva que mostra, em média, o efeito daquela variável na previsão do modelo.*

# A ideia conceitual por trás do gráfico

## Definição

- Eixo X: valores da variável escolhida
- Eixo Y: efeito médio dessa variável na previsão do modelo
- Curva crescente: aumentar a variável tende a aumentar a previsão
- Curva decrescente: aumentar a variável tende a diminuir a previsão
- Curva plana: a variável tem pouco ou nenhum efeito médio
- Curvas não lineares revelam efeitos mais complexos



## Por que e quando usar



### Explicabilidade

Tornar previsões compreensíveis para humanos.



### Diagnóstico do modelo

Detectar comportamentos inesperados ou enviesados.



### Comunicação técnica

Apresentar resultados a áreas de negócio sem jargão.



### Conformidade

Apoiar requisitos de auditoria e governança em IA.

M Ó D U L O

# 06

## EC2 Trainium e Inferentia

Para treinar e usar modelos em escala, escolhemos a infraestrutura certa na nuvem.

Na AWS, isso passa pelas famílias de instâncias EC2.

# Famílias de instâncias e seu propósito

## Definição

- Amazon EC2 oferece servidores virtuais sob demanda
- Instâncias são organizadas em famílias com propósitos distintos
- Cada família é otimizada para um tipo de carga de trabalho
- Para IA, duas famílias merecem destaque:
- **Trainium (Trn) — voltada ao treinamento de modelos**
- **Inferentia (Inf) — voltada à inferência (uso) dos modelos**





# Instâncias voltadas ao treinamento de IA

## Definição

- Família de instâncias EC2 desenhada para treinamento de modelos de IA
- Utiliza o chip AWS Trainium, projetado pela própria AWS
- Otimizada para cargas pesadas e prolongadas de aprendizado
- Voltada para treinar modelos de larga escala, inclusive deep learning
- Busca alto desempenho com custo competitivo no treinamento



***Trainium = treinar. É a infraestrutura que suporta a fase de aprendizado dos modelos.***

## Cenários típicos de aplicação



### Modelos de larga escala

Treinamento de redes neurais profundas com grande volume de dados.



### Cargas intensivas

Workloads que exigem muito poder de cálculo durante o aprendizado.



### Custo de treinamento

Alternativa para reduzir custo em ciclos longos de treinamento.




### Cenários de deep learning

Aplicações como visão computacional, NLP e modelos generativos.

# Instâncias voltadas à inferência de IA

## Definição

- Família de instâncias EC2 desenhada para inferência de modelos de IA
- Inferência = usar um modelo já treinado para gerar previsões
- Utiliza o chip AWS Inferentia, projetado pela própria AWS
- Otimizada para baixa latência e alto volume de previsões
- Busca custo por inferência reduzido em produção



***Inferentia = inferir. É a infraestrutura que suporta o uso do modelo já pronto.***

## Cenários típicos de aplicação



### Aplicações em produção

Servir previsões para usuários finais ou sistemas em tempo real.



### Alto volume

Cargas com milhares ou milhões de inferências por dia.



### Custo por inferência

Quando o objetivo é reduzir custo unitário de cada previsão.



### Latência reduzida

APIs de IA, chatbots e cenários sensíveis ao tempo de resposta.

# Trainium vs. Inferentia



## TRAINIUM (Trn)

- Foco em treinar modelos
- Cargas longas e intensivas
- Chip AWS Trainium
- Otimizada para deep learning
- Custo competitivo no treinamento



## INFERENTIA (Inf)

- Foco em inferência (uso)
- Alto volume de previsões
- Chip AWS Inferentia
- Otimizada para baixa latência
- Custo por inferência reduzido

*Regra prática: Trainium para a fase de aprender; Inferentia para a fase de servir.*

# Principais aprendizados da aula

- 1 MSE e RMSE medem o erro do modelo; o RMSE é mais interpretável
- 2  $R^2$  mede o poder explicativo do modelo, complementando o erro
- 3 PDPs traduzem o comportamento do modelo em curvas explicáveis
- 4 Trainium é a infraestrutura AWS otimizada para treinar modelos  
Inferentia é a infraestrutura AWS otimizada para servir modelos

## P e r g u n t a 1

Uma instituição acadêmica deseja desenvolver seu próprio modelo de linguagem avançado (LLM) utilizando exclusivamente dados internos de pesquisa. A instituição está focada em reduzir o impacto ambiental durante o processo de treinamento. Qual tipo de instância Amazon EC2 é mais indicada para minimizar esse impacto?

- (A) Amazon EC2 série C
- (B) Amazon EC2 série P
- (C) Amazon EC2 série Trn
- (D) Amazon EC2 série G

## P e r g u n t a 1

Uma instituição acadêmica deseja desenvolver seu próprio modelo de linguagem avançado (LLM) utilizando exclusivamente dados internos de pesquisa. A instituição está focada em reduzir o impacto ambiental durante o processo de treinamento. Qual tipo de instância Amazon EC2 é mais indicada para minimizar esse impacto?

- (A) Amazon EC2 série C
- (B) Amazon EC2 série P
- (C) Amazon EC2 série Trn**
- (D) Amazon EC2 série G



## P e r g u n t a 1

Uma universidade utiliza modelos de Machine Learning para prever a taxa de evasão dos estudantes ao final de cada semestre. Um analista de dados está elaborando um relatório sobre os modelos desenvolvidos com o objetivo de garantir transparência e explicabilidade para os coordenadores acadêmicos. O que o analista deve apresentar no relatório para atender às exigências de transparência e explicabilidade?

- (A) Código para treinamento de modelo
- (B) Gráficos de dependência parcial (PDPs)
- (C) Dados de amostra para treinamento
- (D) Tabelas de convergência de modelo

## P e r g u n t a 1

Uma universidade utiliza modelos de Machine Learning para prever a taxa de evasão dos estudantes ao final de cada semestre. Um analista de dados está elaborando um relatório sobre os modelos desenvolvidos com o objetivo de garantir transparência e explicabilidade para os coordenadores acadêmicos. O que o analista deve apresentar no relatório para atender às exigências de transparência e explicabilidade?

- (A) Código para treinamento de modelo
- (B) Gráficos de dependência parcial (PDPs)**
- (C) Dados de amostra para treinamento
- (D) Tabelas de convergência de modelo