

Kendra e MLOps Construindo pipelines de IA na AWS



Amazon Kendra, ciclo de ML, EDA, Data Wrangler, Feature Store e Model Monitor

Agenda

01 Amazon Kendra

Busca corporativa inteligente baseada em IA

02 Ciclo de ML e Pipeline

Etapas para construir cargas de trabalho de ML

03 Coleta de Dados e EDA

Captura e exploração de dados para alimentar modelos

04 Data Wrangler e Feature Store

Preparação de dados e gestão centralizada de features

05 SageMaker Model Monitor

Acompanhamento de modelos em produção

M Ó D U L O

01

Amazon Kendra


Serviço de busca corporativa que entende perguntas em linguagem natural usando IA

O que é Amazon Kendra?

Definição

- Serviço gerenciado de busca corporativa que entende intenções e contexto das perguntas
- Vai além da busca por palavras-chave compreendendo linguagem natural completa
- Indexa documentos de várias fontes mantendo as permissões originais de acesso
- Retorna respostas precisas, trechos relevantes ou documentos completos

Como Kendra responde



Capacidades do Amazon Kendra

Definição

- Entende perguntas em linguagem natural e devolve a resposta exata quando possível
- Indexa conteúdos em S3, SharePoint, Confluence, Salesforce e bancos de dados
- Aprende com o uso, melhorando os resultados conforme os usuários interagem
- Respeita permissões existentes para que cada usuário só veja o que pode acessar

Busca semântica

Compreende contexto e sinônimos, não depende de coincidência de palavras

Conectores

Mais de 40 conectores nativos para fontes corporativas comuns

Permissões

Filtros automáticos por usuário, grupo ou perfil de acesso

Kendra x busca tradicional

Definição

- Buscadores tradicionais retornam páginas que contêm as palavras digitadas
- Kendra identifica intenção e devolve respostas diretas quando possível
- Reconhece sinônimos, jargões e termos específicos do domínio da empresa
- Reduz tempo gasto pelos usuários procurando informação em sistemas dispersos
- Não substitui a busca tradicional, mas eleva a qualidade da experiência corporativa

DESTAQUE

Sem treinar

Kendra usa modelos pré-treinados pela AWS, dispensando esforço de treinar IA própria para começar a usar.

Onde aplicar o Kendra

Definição

- Empresas adotam Kendra para que funcionários encontrem informação rapidamente
- Atende setores como atendimento, RH, jurídico, pesquisa e suporte técnico
- Reduz dependência de consultas humanas a especialistas para perguntas comuns
- É também a base de chatbots corporativos quando combinado com LLMs em RAG
- Aumenta a produtividade ao centralizar conhecimento espalhado em silos

Setores que mais usam

Atendimento

Respostas a clientes via FAQs e bases internas

Recursos Humanos

Buscas em manuais, políticas e benefícios

Jurídico

Localização de cláusulas em contratos e processos

Pesquisa

Consulta a artigos científicos e relatórios técnicos

Amazon Kendra x Amazon OpenSearch

Aspecto	Amazon Kendra	Amazon OpenSearch
Foco	Busca corporativa em linguagem natural	Busca, análise e observabilidade
Tipo de consulta	Pergunta natural com resposta direta	Palavra-chave, filtros e busca vetorial
Configuração	Pronto para uso, baixa configuração	Mais flexível, exige modelagem do índice
IA Generativa	Atendimento e knowledge bases corporativas	Logs, métricas e busca técnica

M Ó D U L O

02

Ciclo de Vida de ML


Visão geral das fases para construir, implantar e operar uma carga de trabalho de machine learning

Sequência de criação de uma carga de ML

Definição

- Toda carga de trabalho de ML segue uma sequência clara, do problema à operação
- Começa com a definição do problema e das métricas de sucesso do negócio
- Passa pelo desenvolvimento do modelo com dados, treino e avaliação
- Termina com a implantação em produção e o monitoramento contínuo do desempenho
- Sem essa visão de ciclo, projetos de ML viram experimentos isolados sem valor

Estrutura básica



As 4 etapas do ciclo de ML

1

Definir

Identificar problema de negócio, métricas de sucesso e disponibilidade de dados

2

Desenvolver

Coletar dados, treinar e avaliar o modelo até atingir desempenho aceitável

3

Implantar

Disponibilizar o modelo em endpoint ou pipeline para consumo da aplicação

4

Monitorar

Acompanhar performance em produção e retreinar quando os dados mudarem

O ciclo é iterativo: monitorar gera aprendizados que voltam para a etapa de definir

ML é como cozinhar

Ingredientes

Os dados são os ingredientes do modelo: sem qualidade, o resultado decepciona.

Preparo

Treinar é o preparo: combinar ingredientes na ordem certa com o método correto.

Provar

Avaliar é provar antes de servir, garantindo que o resultado atende ao padrão.

Servir

Implantar e monitorar é servir e ouvir o feedback dos clientes para ajustar.

M Ó D U L O

03

Pipeline de ML em detalhe

As fases granulares de um pipeline de machine learning, da coleta ao monitoramento

Cinco etapas do pipeline de ML



Coleta de dados

Definição

- Captura de dados de várias fontes em formato adequado para análise e treino
- Deve ser tratada como pipeline contínuo, não como atividade pontual de projeto
- Inclui captura, validação, deduplicação e versionamento dos dados
- A qualidade da coleta define o teto de qualidade do modelo final
- Erros comuns incluem dados desatualizados, vieses e formatos inconsistentes

ANALOGIA

Ingredientes

Sem ingredientes de qualidade, mesmo o melhor cozinheiro não faz boa comida em ML, dados ruins geram modelos ruins, sem exceção.

Preparação de dados

Definição

- Etapa em que dados brutos viram dados utilizáveis para o treinamento do modelo
- Costuma consumir 60% a 80% do tempo total de um projeto de ML
- Inclui limpar valores ausentes, normalizar escalas e codificar variáveis
- Também envolve dividir os dados em treino, validação e teste
- Boa preparação reduz necessidade de algoritmos complexos no treinamento

Distinção essencial

Limpeza

Remover ruído, valores faltantes e inconsistências dos dados

Transformação

Ajustar formato, escala e representação para o algoritmo escolhido

Treinamento do modelo

Definição

- Etapa em que o algoritmo processa os dados preparados e ajusta o modelo
- Envolve definir algoritmo, hiperparâmetros e estratégia de validação
- Usa grande capacidade computacional, em CPU, GPU ou hardware especializado
- É comum testar várias combinações para encontrar a melhor configuração
- O resultado é um artefato de modelo pronto para avaliação e implantação

Características

Algoritmo

Define como o modelo aprende com os dados

Hiperparâmetros

Configurações do algoritmo, ajustadas em tuning

Hardware

CPU, GPU ou aceleradores conforme o modelo

Tempo

Horas, dias ou semanas dependendo do volume

Avaliação do modelo

Definição

- Etapa em que medimos a qualidade do modelo em dados que ele não viu durante o treino
- Garante que o modelo generaliza, em vez de apenas decorar os exemplos
- Usa métricas alinhadas ao tipo de problema e ao impacto no negócio
- Métricas isoladas não bastam; o modelo precisa ser avaliado em cenários reais
- Resultados ruins na avaliação exigem voltar para preparação ou treinamento

MÉTRICAS × PRINCIPAIS

Classificação

Treinamento: Acerto, precisão, recall

Inferência: F1-score e matriz de confusão

Regressão

Treinamento: Erro médio absoluto e RMSE

Inferência: R^2 para variância explicada

Negócio

Treinamento: Receita gerada, fraudes detectadas

Inferência: Métricas conectadas ao impacto

Implantação e monitoramento

Definição

- Implantação coloca o modelo em ambiente acessível pelas aplicações
- Pode ocorrer como endpoint em tempo real, em lote ou em dispositivos
- Requer atenção a versionamento, escalabilidade e segurança do endpoint
- Monitorar é acompanhar o modelo em produção para detectar desvios
- Sem monitoramento, modelos perdem qualidade silenciosamente com o tempo

M Ó D U L O

04

Coleta de Dados

Como capturar e gerenciar dados de qualidade para alimentar pipelines de machine learning

Coleta como pipeline contínuo

Definição

- A coleta deve ser pensada como pipeline contínuo, com responsáveis e cadência claros
- Dados envelhecem rápido, exigindo atualização e revalidação periódicas
- Cada nova fonte adiciona complexidade e precisa ser tratada como peça do pipeline
- Sem governança, dados se acumulam sem qualidade e geram retrabalho constante
- Pipelines bem definidos viabilizam reuso e aceleram novos projetos de ML

Pipeline

Coleta é fluxo contínuo, não evento isolado de projeto

Contínuo

Dados envelhecem, mudam e exigem atualização constante

Erros comuns na coleta de dados

Definição

- Coletar dados desatualizados que não refletem a realidade atual do negócio
- Ignorar vieses históricos presentes nos dados que podem ser amplificados pelo modelo
- Misturar formatos e padrões inconsistentes entre fontes diferentes
- Não validar a qualidade dos dados antes de avançar para a preparação
- Subestimar volume necessário para que o modelo generalize com confiança

Boas práticas de coleta de dados

Boas práticas

- Definir claramente quais dados coletar antes de começar
- Versionar todos os datasets utilizados em treino e avaliação
- Documentar origem, frequência e responsável por cada fonte
- Validar qualidade automaticamente em cada nova carga
- Estabelecer rotinas de atualização periódica das bases

A evitar

- Coletar tudo sem critério e decidir o uso depois
- Misturar dados de teste e treino sem rastreabilidade
- Usar amostras pequenas para representar populações inteiras
- Tratar coleta como tarefa única e não como pipeline
- Ignorar requisitos de privacidade e governança dos dados

M Ó D U L O

05

Análise Exploratória (EDA)

Investigando os dados antes de modelar para entender padrões, qualidade e relações

O que é Análise Exploratória?

Definição

- Sigla para Exploratory Data Analysis, ou análise exploratória de dados
- Etapa em que investigamos os dados sem hipóteses fixas, deixando os números falarem
- Combina estatísticas descritivas com visualizações para entender o conjunto
- Revela padrões, anomalias e relações entre variáveis antes do treinamento
- Dispensável apenas em pipelines maduros com dados muito conhecidos

EDA x Análise final

Aspecto	EDA	Análise final
Quando ocorre	Antes do treinamento do modelo	Após implantar e operar o modelo
Objetivo	Entender dados sem hipóteses fixas	Validar resultado e medir impacto
Ferramentas	Pandas, Matplotlib, Seaborn, Data Wrangler	Painéis, dashboards e relatórios executivos
Saídas	Insights sobre estrutura e qualidade	Decisões e ajustes em produção
Audiência	Cientistas de dados e engenheiros de ML	Stakeholders, gestores e área de negócio

Quando aplicar EDA?

Início de projeto	Sempre que conhecemos pouco a fundo o conjunto de dados disponível
Após coleta nova	Quando uma fonte nova é incorporada ao pipeline de dados
Antes de modelar	Para escolher variáveis, transformações e estratégia de treino
Em problemas teimosos	Quando o modelo não converge ou tem desempenho abaixo do esperado
Comunicar negócio	Para apresentar achados a stakeholders antes de investir em modelagem

M Ó D U L O

06

Data Wrangler e Feature Store

Preparação visual de dados e gestão centralizada de features para treinamento e inferência

O que é SageMaker Data Wrangler?

Definição

- Ferramenta visual do SageMaker Studio para preparar dados sem escrever muito código
- Conecta-se a fontes como S3, Athena, Redshift, Snowflake e Salesforce
- Inclui mais de 300 transformações prontas para limpeza, escalas e codificações
- Permite visualizar distribuições e detectar problemas durante a preparação
- Exporta o fluxo de transformações como código para reuso em pipelines de produção

POR QUE USAR

Wrangler

Reduz drasticamente o tempo de preparação de dados ao combinar interface visual, mais de 300 transformações prontas e exportação direta para pipelines de produção.

Etapas no Data Wrangler

Definição

- Importar dados de uma ou várias fontes conectadas pelo Data Wrangler
- Explorar com estatísticas e visualizações para entender o conjunto
- Aplicar transformações encadeadas em uma sequência reproduzível
- Validar resultado da preparação antes de exportar o fluxo
- Exportar para um pipeline de produção como código ou job recorrente

SageMaker Feature Store

- Repositório centralizado para armazenar, versionar e compartilhar features de ML
- Garante que a mesma feature seja usada no treino e na inferência sem divergência
- Suporta dois modos: online para baixa latência e offline para treinamento em lote
- Permite que múltiplos times reutilizem features sem recalcular tudo do zero
- Reduz erros causados por inconsistências entre dados de treino e produção

Ideia central

Features bem gerenciadas evitam retrabalho entre treino e inferência e mantêm consistência ao longo do ciclo.

Inconsistência entre features de treino e produção é causa comum de degradação silenciosa de modelos.

M Ó D U L O

07

SageMaker Model Monitor

Acompanhamento contínuo de modelos em produção para
detectar desvios e degradação

O que é SageMaker Model Monitor?

Definição

- Serviço gerenciado do SageMaker para monitorar modelos depois de implantados
- Compara dados de produção com a distribuição original usada no treinamento
- Detecta desvios em dados, qualidade do modelo, vieses e atribuição de features
- Gera alertas quando os desvios ultrapassam limites configurados pelo time
- Integra-se com SageMaker Endpoints sem precisar mudar o código da aplicação

Por que monitorar modelos?

Mudanças nos dados

Dados de produção mudam com o tempo, e o modelo deixa de representá-los

Queda silenciosa

Sem monitoramento, qualidade cai sem ninguém perceber até dar problema

Decisões críticas

Modelos influenciam decisões sensíveis em finanças, saúde e segurança

Compliance e auditoria

Reguladores exigem evidência contínua de que modelos operam dentro do esperado

Como funciona o Model Monitor

Definição

- Captura uma linha de base estatística a partir dos dados originais de treinamento
- Coleta amostras das requisições reais que chegam ao endpoint em produção
- Compara as duas distribuições para detectar desvios de dados ou de qualidade
- Gera relatórios periódicos e dispara alertas quando os limites são ultrapassados
- Permite ao time decidir entre retreinar, ajustar regras ou investigar a causa

Fluxo de monitoramento



Da linha de base ao alerta de desvio em produção

Recapitulando os conceitos da aula

- Amazon Kendra entrega busca corporativa em linguagem natural com base em IA
- O ciclo de ML tem quatro etapas: definir, desenvolver, implantar e monitorar
- Pipeline de ML granular cobre coleta, preparação, treinamento, avaliação e implantação
- Coleta de dados é processo contínuo, e qualidade dos dados define teto do modelo
- EDA investiga os dados antes de modelar para evitar surpresas no treino
- SageMaker Data Wrangler acelera preparação de dados com interface visual
- SageMaker Feature Store centraliza features para treino e inferência consistentes
- SageMaker Model Monitor detecta drift e degradação de modelos em produção

P e r g u n t a 1

Em um projeto de ML, uma equipe descobriu que após o deploy a precisão do modelo caiu drasticamente devido a mudanças nos dados em produção. Qual ferramenta da AWS deveria ter sido usada para detectar esse problema?

- (A) SageMaker Data Wrangler
- (B) SageMaker Feature Store
- (C) SageMaker Model Monitor
- (D) Amazon Kendra

P e r g u n t a 1

Em um projeto de ML, uma equipe descobriu que após o deploy a precisão do modelo caiu drasticamente devido a mudanças nos dados em produção. Qual ferramenta da AWS deveria ter sido usada para detectar esse problema?

- (A) SageMaker Data Wrangler
- (B) SageMaker Feature Store
- (C) SageMaker Model Monitor**
- (D) Amazon Kendra