

Treinamento de Modelos Hiperparâmetros, épocas e ajuste fino

Pré-processamento, treinamento, fine-tuning, hiperparâmetros, overfitting e underfitting

Agenda

01 Preparação de Dados

Pré-processamento, engenharia de atributos e Feature Store

02 Treinamento e Estratégias

Datasets de benchmark, pré-treino continuado e fine-tuning

03 Hiperparâmetros de Inferência

Temperatura, top-k e máximo de tokens em LLMs

04 Hiperparâmetros e Épocas

Conceitos de hiperparâmetros e papel das épocas no treino

05 Overfitting e Underfitting

Diagnóstico e correção dos extremos de ajuste do modelo

M Ó D U L O

01

Preparação de Dados


Pré-processamento, engenharia de atributos, Feature Store e data augmentation

O que é pré-processamento?

Definição

- Conjunto de operações que transformam dados brutos em formato adequado para o treinamento
- Inclui limpeza, normalização, codificação e divisão em treino, validação e teste
- Tem impacto direto na qualidade do modelo final e costuma consumir maior parte do projeto
- Etapa essencial mesmo quando os dados parecem prontos à primeira vista

Fluxo de preparação



Engenharia de atributos

Definição

- Processo de criar variáveis informativas a partir dos dados disponíveis
- Boa engenharia de atributos pode superar algoritmos mais sofisticados
- Combina conhecimento do negócio com técnicas estatísticas e matemáticas
- Pode incluir agregações temporais, razões, codificações e interações entre features

Criação

Derivar novas variáveis a partir das existentes com regras de negócio ou agregações

Seleção

Escolher as variáveis mais relevantes e descartar as redundantes ou ruidosas

Transformação

Mudar formato, escala ou representação para ajudar o algoritmo a aprender melhor

SageMaker Feature Store

Definição

- Repositório centralizado para armazenar, versionar e compartilhar features de ML
- Garante que a mesma feature seja usada em treino e inferência sem divergência
- Suporta dois modos: online para baixa latência e offline para treinamento em lote
- Permite que múltiplos times reutilizem features sem recalculá-las tudo do zero
- Reduz erros causados por inconsistências entre dados de treino e produção

DESTAQUE

Reuso

Feature Store evita que cada time recalcule as mesmas features e garante consistência entre o que vê o treino e o que vê a inferência.

Slide 6

JC1

Assunto ja visto no encontro anterior: 11

Josely Castro; 2026-05-27T18:22:22.905

Data augmentation

Definição

- Técnica que amplia datasets de treino criando variações dos exemplos existentes
- Ajuda o modelo a generalizar melhor e reduz risco de overfitting
- Especialmente útil quando o dataset original é pequeno ou desbalanceado
- Pode ser aplicada em tempo de treino ou criar dataset estendido offline
- As técnicas variam por tipo de dado: imagem, texto, áudio e tabular

Técnicas por tipo de dado

Texto

Rotação, recorte, espelhamento e variações de cor

Imagem

Sinônimos, paráfrases e tradução de ida e volta

Áudio

Mudança de tom, ruído de fundo e variação de velocidade

Tabular

SMOTE para classes raras e perturbação de variáveis

Pré-processamento x Engenharia de atributos

Aspecto	Pré-processamento	Engenharia de atributos
Objetivo	Limpar e preparar dados existentes	Criar variáveis informativas para o modelo
Tipo de operação	Mecânica: limpeza, normalização, divisão	Criativa: depende de conhecimento do negócio
Quem faz	Engenheiro de dados ou ML	Cientista de dados com domínio do problema
IA Generativa	Garantia de qualidade dos dados de entrada	Pode superar algoritmos mais sofisticados

M Ó D U L O

02

Treinamento de Modelos

Como os modelos aprendem com os dados, e como medimos o desempenho com datasets de benchmark

O que é treinamento?

Definição

- Processo em que o algoritmo ajusta os parâmetros do modelo a partir dos dados
- Compara a previsão do modelo com a resposta correta usando uma função de erro
- Ajusta os pesos do modelo iterativamente até reduzir o erro a um nível aceitável
- Demanda dados, algoritmo escolhido e capacidade computacional adequada
- Resulta em um artefato de modelo pronto para ser avaliado e implantado

Etapas do treinamento

1

Carregar

Carregar dados preparados nos formatos esperados pelo algoritmo

2

Inicializar

Inicializar o modelo com pesos aleatórios e definir hiperparâmetros

3

Iterar

Iterar épocas, calculando erro e ajustando pesos para reduzi-lo

4

Salvar

Salvar o modelo treinado como artefato pronto para avaliação

O processo combina dados, algoritmo, hiperparâmetros e poder computacional

Datasets de benchmark

ImageNet

Padrão para classificação de imagens com mais de 1 milhão de exemplos rotulados.

GLUE e MMLU

Avaliam compreensão e raciocínio em modelos de linguagem em vários idiomas.

COCO

Imagens com legendas para tarefas multimodais e detecção de objetos.

LibriSpeech

Áudio em inglês para reconhecimento de fala e processamento de áudio.

M Ó D U L O

03

Estratégias de Treinamento

Pré-treino do zero, pré-treino continuado, fine-tuning e abordagens auxiliares

Cinco estratégias de treinamento

01

Pré-treino

Treinar do zero em grandes volumes de dados, exigindo alto custo e tempo

02

Pré-treino continuado

Continuar o pré-treino de um modelo existente com dados de domínio específico

03

Fine-tuning

Ajustar um modelo pré-treinado para uma tarefa com pares de exemplos rotulados

04

RLHF

Aprendizado por reforço com feedback humano para alinhar respostas a preferências

05

Few-shot

Guiar o modelo apenas com exemplos no prompt, sem treinamento adicional

Pré-treino continuado

Definição

- Continua o treinamento de um modelo já pré-treinado em dados de domínio específico
- Não exige pares rotulados, usa textos e documentos do domínio
- Útil para adaptar vocabulário, estilo e contexto do setor
- Mais barato e rápido que treinar do zero, ainda exige bom volume de dados
- Costuma vir antes do fine-tuning supervisionado em projetos de domínio fechado

ANALOGIA

Especialização

Pense no pré-treino continuado como um médico generalista fazendo residência em uma área: aproveita toda a base anterior e adiciona profundidade no domínio escolhido.

Fine-tuning

Definição

- Ajustar um modelo pré-treinado em uma tarefa específica usando pares rotulados
- Exige pares de entrada e saída esperada, mas em volume bem menor que o pré-treino
- Foca o modelo em comportamento desejado: respostas, formatos, estilo
- Pode ser feito em todo o modelo ou em poucas camadas com técnicas como LoRA
- Costuma ser combinado com pré-treino continuado em projetos corporativos

Distinção essencial

Pré-treino continuado

Aprende vocabulário e estilo: dados não rotulados do domínio

Fine-tuning

Aprende comportamento: pares rotulados do que entra e do que sair

Tipos de fine-tuning

Definição

- Existem diferentes formas de fazer fine-tuning conforme custo e flexibilidade
- Full fine-tuning ajusta todos os pesos, exige mais hardware e dados
- LoRA e PEFT ajustam poucas camadas e mantêm o modelo original quase intacto
- Instruction tuning treina o modelo a seguir instruções em formato natural
- A escolha depende de orçamento, dados disponíveis e objetivo final

Modalidades

Full

Ajusta todos os pesos do modelo

LoRA

Adiciona pequenas matrizes treináveis

PEFT

Ajusta poucos parâmetros eficientes

Instruction

Treina a obedecer comandos

Quando usar cada estratégia

Definição

- A escolha entre estratégias depende de dados disponíveis e custo aceitável
- Pré-treino do zero faz sentido apenas para grandes empresas com dados massivos
- Pré-treino continuado é ideal para adaptar o vocabulário a um domínio fechado
- Fine-tuning é o caminho para tarefas específicas com pares de exemplos
- Few-shot prompting resolve casos pontuais sem qualquer treinamento adicional

ESTRATÉGIA × CONTEXTO

Domínio novo

Treinamento: Pré-treino continuado

Inferência: Vocabulário adaptado

Tarefa específica

Treinamento: Fine-tuning supervisionado

Inferência: Comportamento desejado

Caso pontual

Treinamento: Few-shot prompting

Inferência: Sem retraining adicional

Custos e benefícios das estratégias

Definição

- Pré-treino do zero pode custar milhões de dólares e meses de execução
- Pré-treino continuado custa fração do anterior e leva dias ou semanas
- Fine-tuning de poucas camadas pode rodar em horas, com hardware acessível
- Few-shot e RAG não envolvem treino, ideais para iterar rápido sobre dados
- Combinar estratégias permite balancear qualidade, tempo e investimento

M Ó D U L O

04

Hiperparâmetros

Configurações que controlam o aprendizado e o comportamento do modelo durante o treinamento

O que são hiperparâmetros?

Definição

- Hiperparâmetros são configurações que controlam como o modelo aprende durante o treinamento
- Não são aprendidos pelo modelo, são definidos previamente pelo time de ML
- Exemplos incluem taxa de aprendizado, tamanho de batch e número de épocas
- Boa escolha acelera convergência e reduz risco de overfitting ou underfitting
- Encontrar bons hiperparâmetros costuma exigir experimentação organizada

Antes

Configurados antes do treinamento começar

Durante

Não mudam ao longo da execução do treinamento

Tipos de hiperparâmetros

Definição

- Taxa de aprendizado controla o tamanho do passo nos ajustes de pesos
- Tamanho de batch define quantos exemplos passam pela rede a cada atualização
- Número de épocas determina quantas vezes o dataset será percorrido
- Regularização reduz overfitting penalizando pesos muito grandes
- Arquitetura define camadas, neurônios e ativações que compõem o modelo

Ajuste de hiperparâmetros

Métodos comuns

- Grid search testa todas as combinações em uma grade definida
- Random search amostra combinações aleatórias dentro do espaço de busca
- Otimização bayesiana usa resultados anteriores para escolher próximas tentativas
- SageMaker oferece tuning gerenciado integrado ao treinamento
- Validação cruzada ajuda a comparar combinações com mais robustez

Trade-offs

- Espaço de busca grande explode em custo computacional
- Resultados muito sensíveis a dados específicos do experimento
- Bons hiperparâmetros não compensam dados ruins ou modelo inadequado
- Otimizar a métrica errada leva a um modelo bonito que falha no negócio
- Documentar a busca evita repetir os mesmos experimentos no futuro

M Ó D U L O

05

Épocas no Treinamento

Quantas vezes o modelo passa pelos dados durante o treinamento, e por que isso importa

O que são épocas?

Definição

- Uma época é uma passagem completa pelos dados de treino durante o aprendizado
- A cada época, os pesos do modelo são ajustados para reduzir o erro
- Modelos costumam treinar por dezenas a milhares de épocas
- O número certo depende do volume de dados, da arquitetura e da tarefa
- Acompanhar erro de treino e validação em cada época é essencial

Poucas épocas x Muitas épocas

Aspecto	Poucas épocas	Muitas épocas
Convergência	Modelo pode ficar subajustado	Pode atingir bom ajuste, ou sobreajustar
Risco principal	Underfitting nos dados	Overfitting depois do ponto ótimo
Tempo e custo	Treinamento curto e barato	Treinamento longo e caro
Validação	Curva pode estar incompleta	Curva mostra ponto de virada
Decisão	Aumentar até a curva estabilizar	Reduzir ou usar early stopping

Quantas épocas usar?

Datasets pequenos

Mais épocas tendem a ajudar, pois o modelo precisa de mais passagens para aprender

Datasets grandes

Menos épocas costumam bastar, pois cada passada já oferece muita informação

Modelos grandes

Cuidado com excesso de épocas, alto risco de overfitting em poucas iterações

Fine-tuning

Geralmente bastam de uma a cinco épocas para ajustar o modelo à tarefa

Decisão prática

Use validação para detectar o ponto de parar com early stopping

M Ó D U L O

06

Hiperparâmetros de Inferência

Temperatura, top-k e máximo de tokens guiam a geração sem alterar o modelo

Hiperparâmetros de inferência

Definição

- Configuram como o modelo escolhe o próximo token durante a geração
- Não alteram o modelo treinado, apenas guiam suas saídas em tempo real
- Permitem ajustar criatividade, precisão e custo conforme o caso de uso
- Os principais são temperatura, top-k, top-p e máximo de tokens
- Uma boa escolha pode mudar drasticamente a experiência do usuário final

GERAÇÃO

Saída

Esses parâmetros controlam como o modelo gera saída token por token, sem alterar seus pesos internos, e podem ser ajustados a cada chamada.

Temperatura

Definição

- Controla o quanto o modelo é determinístico ou criativo na escolha do próximo token
- Valores baixos como 0.1 produzem respostas previsíveis e factuais
- Valores altos como 1.0 ou mais aumentam variação e criatividade
- Para tarefas como código e dados, temperatura próxima de zero costuma ser melhor
- Para criação de conteúdo e brainstorming, valores maiores tendem a ajudar

Top-k e máximo de tokens

Definição

- Top-k limita o sorteio do próximo token aos K tokens mais prováveis em cada passo
- Top-k pequeno torna a saída mais previsível, top-k maior dá mais variedade
- Máximo de tokens define o tamanho-limite da resposta gerada pelo modelo
- Esse limite controla custo, latência e impede respostas longas demais
- Bons valores dependem do caso: chatbot curto, resumo médio, análise longa

Ideia central

Hiperparâmetros de inferência são alavancas para equilibrar criatividade, precisão e custo em cada chamada.

Pequenos ajustes em temperatura, top-k e tokens podem mudar a experiência percebida do usuário final.

M Ó D U L O

07

Overfitting e Underfitting

Os dois extremos de ajuste do modelo, como diagnosticá-los e corrigi-los

Overfitting e underfitting

Definição

- São os dois extremos opostos de ajuste do modelo aos dados de treino
- Overfitting acontece quando o modelo aprende ruído e detalhes que não generalizam
- Underfitting acontece quando o modelo é simples demais para capturar os padrões
- Ambos resultam em desempenho ruim em produção, ainda que por motivos opostos
- O objetivo é encontrar o equilíbrio entre os dois extremos

Como detectar e evitar

Detectar overfitting

Acompanhar a diferença entre erro de treino e erro de validação a cada época

Evitar overfitting

Aplicar regularização, dropout, data augmentation ou aumentar dados de treino

Detectar underfitting

Modelo não atinge desempenho mínimo nem nos próprios dados de treinamento

Evitar underfitting


Aumentar capacidade do modelo, criar mais features ou treinar por mais épocas

Buscando o equilíbrio

Definição

- O modelo ideal está entre o simples demais e o complexo demais para os dados
- Curvas de erro de treinamento e validação ajudam a localizar o ponto de virada
- Early stopping interrompe o treino quando a validação começa a piorar
- Aumentar volume e qualidade dos dados é a forma mais robusta de evitar overfitting
- O equilíbrio é busca contínua, não estado final que se atinge uma vez

Pontos de ajuste



O ponto ideal fica entre o simples demais e o complexo demais

Recapitulando os conceitos da aula

- Pré-processamento e engenharia de atributos preparam dados para o treinamento
- Feature Store centraliza features e mantém consistência entre treino e inferência
- Data augmentation amplia datasets criando variações dos exemplos existentes
- Datasets de benchmark medem qualidade dos modelos em tarefas conhecidas
- Pré-treino continuado adapta vocabulário; fine-tuning ajusta a tarefas específicas
- Hiperparâmetros são definidos antes do treino e ajustados via tuning
- Temperatura, top-k e máximo de tokens guiam a geração na inferência
- Overfitting e underfitting são extremos de ajuste, evitados com técnicas apropriadas

 **Explore na prática:**

<https://brianmonteiro54.github.io/Balaio-de-Gatos/aula12/>