

Tuning, Métricas MLOps e operação de modelos



HPO, Autopilot, BLEU, ROUGE, BERTScore, MLOps, DeepAR e monitoramento

Agenda

01 Tuning e AutoML

HPO, Autopilot e adaptação de domínio no SageMaker

02 Métricas para FMs

BLEU, ROUGE, BERTScore e como avaliar modelos generativos

03 MLOps e DeepAR

Operação de modelos com versionamento, experimentos e algoritmo de previsão

04 Implantação

SageMaker Endpoints e modelos de deploy gerenciado e auto-hospedado

05 Monitoramento e Retreinamento

Como acompanhar modelos em produção e quando retreinar

M Ó D U L O

01

Tuning e AutoML


Hyperparameter Optimization, SageMaker Autopilot e adaptação de domínio para acelerar projetos

O que é Hyperparameter Optimization?

Definição

- Processo automatizado de buscar a melhor combinação de hiperparâmetros para um modelo
- Substitui a tentativa manual por uma busca sistemática no espaço de configurações
- Costuma usar uma métrica de validação como guia para identificar a melhor combinação
- SageMaker oferece HPO gerenciado integrado aos jobs de treinamento

Espaço de busca



Métodos de busca em HPO

Definição

- Existem várias estratégias para explorar o espaço de hiperparâmetros
- Cada método tem trade-offs entre qualidade da busca e custo computacional
- SageMaker HPO suporta os principais métodos de forma transparente
- Validação cruzada ajuda a comparar combinações de forma robusta

Grid

Testa todas as combinações em uma grade definida pelo time

Random

Amostra combinações aleatórias dentro do espaço de busca

Bayesiano

Usa resultados anteriores para escolher próximas tentativas com mais inteligência

SageMaker Autopilot

Definição

- Serviço de AutoML do SageMaker que automatiza o ciclo completo de criação de modelos
- Recebe um dataset tabular e a coluna alvo, e devolve modelos treinados e avaliados
- Realiza pré-processamento, seleção de algoritmo, treino e tuning automaticamente
- Gera notebooks reproduzíveis explicando cada decisão tomada pelo serviço
- Indicado para times sem especialistas em ML que precisam de baseline rápido

DESTAQUE

AutoML

Autopilot é a opção certa quando o time tem dados, mas não tem cientistas de ML disponíveis para construir modelo do zero.

Ajuste fino com adaptação de domínio

Definição

- Técnica que adapta um modelo pré-treinado a um domínio específico de aplicação
- Combina pré-treino continuado com fine-tuning supervisionado em sequência
- Apoia projetos em que o vocabulário e o estilo do setor são bem diferentes do geral
- Reduz alucinações ao alinhar o modelo ao contexto do negócio
- Geralmente exige menos dados rotulados que treinar do zero

Onde se aplica

Saúde

Modelos adaptados a prontuários e protocolos clínicos

Jurídico

Adaptação ao vocabulário de petições e contratos

Financeiro

Compreensão de relatórios, regulações e jargão do setor

Indústria

Manuais técnicos, normas e linguagem de engenharia

HPO, Autopilot e Adaptação de Domínio

Aspecto	HPO	Autopilot
Foco	Encontrar melhor combinação de hiperparâmetros	Construir modelo do zero com pouca intervenção
Entrada esperada	Algoritmo definido e espaço de busca	Dataset tabular e variável alvo
Esforço do time	Médio: define algoritmo e métricas	Baixo: configura entrada e analisa resultados
IA Generativa	Já existe modelo, falta otimizar configurações	Não há modelo, precisa gerar baseline rápido

M Ó D U L O

02


Redução de Dimensionalidade

Como reduzir o número de variáveis de um conjunto de dados sem perder informação relevante

O que é redução de dimensionalidade?

Definição

- Conjunto de técnicas para reduzir o número de variáveis de um dataset
- Mantém o máximo possível de informação útil enquanto descarta redundâncias
- Pode ser feita por seleção de variáveis ou por extração de novas features
- Reduz custo computacional, melhora visualização e ajuda a evitar overfitting
- Especialmente útil em datasets com centenas ou milhares de variáveis



Como uma rede neural aprende?

1

PCA

Análise de Componentes Principais, projeta dados em eixos de máxima variância

2

t-SNE

Preserva relações de vizinhança, ótima para visualização em 2D ou 3D

3

UMAP

Mais rápido que t-SNE e preserva estrutura local e global do dataset

4

Autoencoder

Rede neural que aprende representação compacta dos dados de entrada

A escolha da técnica depende do volume de dados e do objetivo do projeto

Quando aplicar redução de dimensionalidade

Visualização

Reduzir para 2D ou 3D para explorar e comunicar padrões a stakeholders.

Performance

Diminuir custo de treino e inferência removendo variáveis pouco informativas.

Anti-overfitting

Modelos com menos features tendem a generalizar melhor para dados novos.

Vetores

Reduzir dimensão de embeddings para acelerar busca semântica em escala.

M Ó D U L O

03

Métricas para Foundation Models

Como avaliar a qualidade de modelos generativos com BLEU, ROUGE e BERTScore

Cinco conceitos sobre avaliação

01	02	03	04	05
Geração	Referência	Métrica	Avaliação	Holístico
Texto produzido pelo modelo a partir de uma entrada ou pergunta	Resposta correta esperada, escrita por humanos ou anotada com cuidado	Forma de comparar geração e referência e atribuir um valor numérico	Conjunto de métricas aplicadas ao modelo para entender seu desempenho real	Avaliação que combina métricas automáticas com análise humana qualitativa

Métricas para FMs

Definição

- Foundation Models geram saída livre, então as métricas tradicionais não bastam
- Métricas para FMs comparam texto gerado com texto de referência ou critérios
- BLEU, ROUGE e BERTScore são as três métricas mais usadas em texto
- Cada métrica enxerga um aspecto diferente: precisão, cobertura ou semântica
- Avaliação completa combina métricas automáticas e revisão humana qualitativa

ANALOGIA

Provador

Pense em métricas como diferentes provadores: um repara no sabor, outro na apresentação, outro no tempero cada um diz algo essencial e nenhum é suficiente sozinho.

BLEU

Definição

- Sigla para Bilingual Evaluation Understudy, criada para tradução automática
- Mede sobreposição de n-gramas entre o texto gerado e o texto de referência
- Quanto maior o BLEU, mais palavras e sequências em comum com a referência
- Funciona melhor quando há mais de uma referência por geração avaliada
- Limitação clara: não captura sinônimos nem reformulações semanticamente equivalentes

Distinção essencial

Forte

Bom para tradução e tarefas com saída próxima da referência

Fraco

Penaliza paráfrases e reformulações mesmo que mantenham o significado

ROUGE

Definição

- Sigla para Recall-Oriented Understudy for Gisting Evaluation
- Foi pensada para avaliar resumos automáticos de textos longos
- Mede o quanto da referência aparece no texto gerado pelo modelo
- Existe em variantes que olham para palavras, sequências ou estrutura
- Costuma ser usada em conjunto com BLEU e revisão humana

Variantes

ROUGE-N

Compara n-gramas comuns

ROUGE-L

Subsequência comum mais longa

ROUGE-W

Versão ponderada da ROUGE-L

ROUGE-S

Pares de palavras pulando termos

BERT Score

Definição

- Métrica que usa o modelo BERT para comparar significado entre textos
- Em vez de palavras, compara representações vetoriais geradas pelo BERT
- Captura sinônimos, reformulações e relações semânticas entre frases
- Custa mais que BLEU e ROUGE por exigir inferência de um modelo a cada par
- Recomendada quando a saída livre exige avaliação semântica e não literal

BERT × TRADICIONAIS

Comparação

Treinamento: BERTScore mede semântica

Inferência: BLEU e ROUGE medem palavras

Sinônimos

Treinamento: BERTScore reconhece equivalentes

Inferência: BLEU e ROUGE penalizam reformulações

Custo

Treinamento: BERTScore exige inferência por par

Inferência: BLEU e ROUGE são mais leves

Como escolher a métrica certa

Definição

- A escolha da métrica depende do tipo de tarefa e do nível de variação da saída
- Tradução costuma usar BLEU, com referências múltiplas quando possível
- Resumo automático geralmente combina ROUGE com revisão humana
- Geração livre, como respostas e diálogos, tende a precisar de BERTScore
- Em produção, métricas automáticas se complementam com avaliação humana

M Ó D U L O

04

Implantação de Modelos

Como disponibilizar modelos para uso real com SageMaker
Endpoints e opções de deploy

O que é implantação?

Definição

- Implantação é a etapa em que o modelo passa a ser usado por aplicações reais
- Pode acontecer como API em tempo real ou processamento em lote
- Demanda atenção a versionamento, escalabilidade, segurança e custo
- Boa implantação prepara terreno para monitorar e retreinar com confiança
- É também onde a maior parte do custo recorrente do projeto se concentra

Online

Responde a cada chamada em tempo real
com baixa latência

Offline

Processa grandes volumes em lote, sem
requisito de latência

SageMaker Endpoints

Definição

- Endpoints são APIs HTTP gerenciadas que servem modelos em tempo real
- SageMaker cuida da infraestrutura, escalabilidade e segurança do endpoint
- Suportam multi-modelo, autoscaling e variantes para testes A/B
- Para cargas em lote, há a alternativa de Batch Transform
- Endpoints serverless atendem cargas com tráfego intermitente sem pagar tempo ocioso

Deploy gerenciado x auto-hospedado

Gerenciado

- Infraestrutura, segurança e escalabilidade tratadas pelo SageMaker
- Configurações de autoscaling e logs entregues prontas
- Implementação rápida com poucas linhas de código ou via console
- Pago pelo tempo de instância e pelo modelo de invocação escolhido
- Indicado para times pequenos focados em modelo e aplicação

Auto-hospedado

- Cliente assume gestão de servidor, segurança e monitoramento
- Maior controle sobre customização de runtime e dependências
- Pode reduzir custo unitário em altíssimo volume bem dimensionado
- Exige time com expertise em SRE, segurança e cloud
- Pode ser combinado com containers próprios em SageMaker BYOC

M Ó D U L O

05


MLOps e Experimentos

Práticas e ferramentas para operar modelos de ML de forma confiável e reproduzível

O que é MLOps?

Definição

- Conjunto de práticas que une ML, engenharia de software e operações
- Trata o ciclo de vida do modelo como um pipeline reproduível e versionado
- Inclui dados, modelo, código, infraestrutura e métricas em um só processo



- Reduz tempo entre experimento e produção e melhora qualidade no longo prazo
- Sem MLOps, projetos ficam dependentes de uma única pessoa e quebram no deploy

MLOps x DevOps

Aspecto	MLOps	DevOps
Foco principal	Ciclo de vida de modelos de ML	Ciclo de vida de software tradicional
Artefatos versionados	Dados, modelo, código e configurações	Código, dependências e infraestrutura
Métrica chave	Acurácia e drift do modelo em produção	Disponibilidade e tempo de resposta
Atualização típica	Retreinamento periódico do modelo	Releases incrementais de funcionalidade
Time envolvido	Cientistas, engenheiros de ML e plataforma	Engenheiros de software e operações

Práticas essenciais de MLOps

Versionamento	Versionar dados, modelos e código para reproduzir qualquer experimento
Experimentos rastreáveis	SageMaker Experiments registra parâmetros, métricas e artefatos por execução
Pipelines automatizados	Pipelines reproduzíveis levam dados a modelo em produção sem etapas manuais
Monitoramento contínuo	Acompanhar drift, qualidade e custo do modelo em tempo real após o deploy
Governança	Documentar decisões, riscos e responsáveis por cada modelo em uso

M Ó D U L O

06

SageMaker DeepAR

Algoritmo do SageMaker para previsão de séries temporais com redes neurais

O que é SageMaker DeepAR?

Definição

- Algoritmo gerenciado do SageMaker para previsão de séries temporais
- Baseado em redes neurais recorrentes, capaz de lidar com múltiplas séries
- Aprende padrões compartilhados entre séries relacionadas dentro do mesmo dataset
- Devolve previsões pontuais e intervalos de confiança para cada ponto futuro
- Útil quando há centenas ou milhares de séries semelhantes a serem previstas

ALGORITMO

DeepAR

Permite treinar um único modelo sobre muitas séries semelhantes, com previsões probabilísticas e variáveis externas integradas.

Como funciona o DeepAR

Definição

- Recebe séries temporais alinhadas com mesmas datas e granularidade
- Aprende um único modelo a partir de muitas séries relacionadas em conjunto
- Pode incorporar variáveis externas como feriados, promoções ou clima
- Treina e implanta dentro do SageMaker como qualquer outro algoritmo gerenciado
- Retorna distribuição completa, permitindo análise probabilística da previsão

Mecanismo de atenção

- Previsão de demanda em varejo com milhares de produtos ao longo do tempo
- Estimativa de carga em redes elétricas, água, telecomunicações e logística
- Planejamento financeiro com previsões de receita por filial, produto ou cliente
- Operações com séries de muitos sensores ou pontos de coleta semelhantes
- Cenários em que prever cada série isoladamente seria caro e impreciso

Ideia central

DeepAR é especialmente forte quando há muitas séries semelhantes para prever em conjunto.

Quanto maior o conjunto de séries relacionadas, mais o modelo aprende padrões compartilhados.

M Ó D U L O

07

Monitoramento e Retreinamento

Como acompanhar modelos em produção e decidir quando retreiná-los para manter qualidade

O que é monitoramento de modelos?

Definição

- Acompanhar continuamente o desempenho do modelo depois que ele entra em produção
- Compara dados de entrada e saída com a distribuição vista durante o treinamento
- Detecta drift de dados, drift de conceito, vieses e queda de qualidade
- Sem monitoramento, modelos perdem qualidade em silêncio até o impacto chegar ao negócio
- Aplicável tanto a modelos de previsão quanto a modelos generativos em uso

Quando retreinar o modelo?

Drift de dados

Distribuição dos dados de entrada mudou em relação ao que foi visto no treino

Drift de conceito

A relação entre entrada e saída mudou, o problema de negócio evoluiu

Queda de métricas

As métricas de qualidade caem abaixo do limite definido com o time de negócio

Cadência fixa

Retreinamento periódico programado, mesmo sem alerta, em domínios voláteis

Ciclo de monitoramento e retreinamento

Definição

- Cada modelo em produção precisa de uma rotina ativa de monitoramento contínuo
- Limites claros para drift e métricas evitam decisões emocionais sobre retreino
- Pipelines de retreinamento automatizam coleta, treino, avaliação e novo deploy
- Sempre validar o novo modelo antes de promover, evitando regressões silenciosas
- MLOps maduro automatiza esse ciclo e mantém qualidade ao longo dos meses

Ciclo de operação



O ciclo é contínuo e permite responder a mudanças do negócio ao longo do tempo

Recapitulando os conceitos da aula

- SageMaker HPO e Autopilot automatizam a busca pela melhor configuração de modelos
- Adaptação de domínio combina pré-treino continuado e fine-tuning para o setor
- Redução de dimensionalidade simplifica dados sem perder informação relevante
- BLEU, ROUGE e BERTScore avaliam qualidade dos modelos generativos por ângulos diferentes
- SageMaker Endpoints implantam modelos como APIs gerenciadas com autoscaling
- MLOps une versionamento, experimentos e monitoramento em um ciclo confiável
- DeepAR é o algoritmo do SageMaker para previsão de séries temporais em escala
- Monitoramento detecta drift e dispara retreinamento para manter o modelo útil

 **Explore na prática:**

<https://brianmonteiro54.github.io/Balaio-de-Gatos/aula13/>

P e r g u n t a 1

Após implantar um modelo em produção, sua equipe percebe que a precisão caiu com o tempo. Qual prática de MLOps deveria ter sido implementada para detectar e corrigir esse problema?

- (A) Versionamento apenas do código fonte
- (B) Monitoramento contínuo e retreinamento periódico
- (C) Deploy mais rápido do modelo
- (D) Aumentar o número de épocas no treino original

P e r g u n t a 1

Após implantar um modelo em produção, sua equipe percebe que a precisão caiu com o tempo. Qual prática de MLOps deveria ter sido implementada para detectar e corrigir esse problema?

- (A) Versionamento apenas do código fonte
- (B) Monitoramento contínuo e retreinamento periódico**
- (C) Deploy mais rápido do modelo
- (D) Aumentar o número de épocas no treino original