

Bedrock e modelos Capacidades, consumo de dívida técnica



Amazon Bedrock, Playground, capacidade sob-demanda e provisionada, dívida técnica em ML

Agenda

01 Dívida Técnica em ML

O que é, como aparece em projetos de ML e como pagar

02 Amazon Bedrock

Visão geral do serviço e dos modelos disponíveis

03 Bedrock Playground

Ambiente para experimentar modelos antes de integrar

04 Capacidade do Bedrock

Modos sob-demanda e provisionada de consumir os modelos

05 Comparação e escolha

Quando usar cada modalidade conforme padrão de uso

M Ó D U L O

01

Dívida Técnica em ML


Como atalhos durante o desenvolvimento se acumulam e impactam projetos de machine learning

O que é dívida técnica?

Definição

- Custo futuro acumulado por escolhas rápidas tomadas durante o desenvolvimento
- Análoga a uma dívida financeira, com juros que crescem se ela não for paga
- Pode ser deliberada para acelerar entrega ou inadvertida por falta de prática
- Em ML, ela aparece em código, dados e modelos, dificultando manutenção

Como se acumula



Tipos de dívida técnica

Definição

- Nem toda dívida técnica é igual: existem origens diferentes e formas distintas de tratar
- Um framework clássico classifica em deliberada ou inadvertida, prudente ou imprudente
- Cada combinação pede uma resposta diferente do time técnico e da liderança
- Reconhecer o tipo é o primeiro passo para definir como pagá-la

Estratégica

Tomada conscientemente para acelerar entrega prioritária e validar hipóteses

Acidental

Surge sem que o time perceba durante o trabalho diário, por falta de prática

Por evolução

Tecnologias e práticas envelhecem em projetos longos, exigindo atualização constante

Dívida técnica em ML

Definição

- Em projetos de ML, dívida técnica acumula em três dimensões diferentes ao mesmo tempo
- No código, scripts manuais e ausência de testes complicam manutenção e reproduzibilidade
- Nos dados, falta de governança, versionamento e monitoramento gera problemas silenciosos
- Nos modelos, falta de versionamento e métricas dificulta saber qual está em produção
- Cada uma dessas frentes precisa de práticas próprias de MLOps para ser controlada

DESTAQUE

Tripla frente

Diferente de software tradicional, dívida em ML acumula em três frentes simultâneas: código, dados e modelos cada uma com seus próprios riscos.

Como identificar dívida técnica

Definição

- Dívida técnica raramente aparece em uma reunião, ela se manifesta em sintomas no dia a dia
- Times atentos a esses sinais conseguem priorizar pagamento antes de virar bloqueio
- Quanto mais sintomas, maior a probabilidade de que a dívida esteja afetando entregas
- Diagnóstico honesto evita decisões baseadas em culpa e abre caminho para refatorar
- Documentar a dívida em backlog torna o tema visível e gerenciável pela liderança

Sinais comuns

Builds lentos

Pipelines que exigem horas para rodar e validar

Deploys arriscados

Cada release exige intervenção manual e gera medo

Bugs recorrentes

Os mesmos defeitos voltam em diferentes formas

Time exausto

Esforço alto para mudanças simples e fadiga crescente

Boa dívida x Má dívida técnica

Aspecto	Boa dívida	Má dívida
Conhecimento	Time sabe que existe e onde está	Acumula em silêncio até virar problema
Plano de pagamento	Tem prazo claro para refatoração	Sem prazo, vira parte permanente
Trade-off	Velocidade hoje em troca de ajuste futuro	Acelera no curto e trava no longo
IA Generativa	Registrada e visível em backlog ou ADR	Esquecida ou ignorada pelo time atual

M Ó D U L O

02


Amazon Bedrock

Plataforma da AWS para acessar modelos fundacionais via API, sem gerenciar infraestrutura

O que é Amazon Bedrock?

Definição

- Serviço gerenciado da AWS que oferece acesso a modelos fundacionais via API
- Reúne modelos de Anthropic, Meta, Amazon, Cohere, Mistral e outros provedores
- Não exige instalação ou hospedagem de modelos pelo cliente
- Inclui recursos como Knowledge Bases, Agents, Guardrails e Playground
- Cobra apenas pelo uso, integrando-se a outros serviços como Lambda e Step Functions



Como começar com o Bedrock

1

Habilitar

Solicitar acesso aos modelos desejados na console do Bedrock

2

Explorar

Testar prompts no Playground antes de escrever código de integração

3

Integrar

Chamar a API InvokeModel a partir da aplicação ou pipeline

4

Iterar

Refinar prompts, parâmetros e modelo com base em métricas reais

Esse ciclo curto reduz tempo entre experimento e produção em projetos novos

Principais recursos do Bedrock

Foundation Models

Catálogo curado de modelos generativos de texto, imagem e embeddings.

Knowledge Bases

Implementa RAG sobre dados privados sem montar infraestrutura de busca vetorial.

Agents

Orquestra chamadas a APIs e ferramentas para resolver tarefas complexas com LLMs.

Guardrails

Filtra conteúdos sensíveis e impõe limites de segurança nas respostas geradas.

M Ó D U L O

03

Conceitos-chave

Modelo, algoritmo, treinamento, inferência e a introdução aos LLMs

Cinco aspectos dos modelos do Bedrock

01	02	03	04	05
Modelo	Família	Tamanho	Custo	Casos de uso
Empresa responsável por criar e treinar o modelo: Anthropic, Meta, Amazon e outras	Linha de modelos relacionados pelo provedor, como Claude, Llama, Titan e Nova	Quantidade de parâmetros do modelo, que afeta qualidade, custo e latência	Cobrança baseada em tokens de entrada e saída, com preços diferentes por modelo	Cada modelo tem combinação preferida de tarefas, idiomas e capacidades multimodais

Anthropic Claude

Definição

- Família de modelos da Anthropic, focada em raciocínio, segurança e contexto longo
- Forte em tarefas analíticas, escrita estruturada e seguir instruções complexas
- Janela de contexto extensa permite processar documentos inteiros em uma chamada
- Modelos vêm em variantes Sonnet e Opus, equilibrando custo e qualidade
- Bom para chatbots corporativos, agentes, análise de documentos e geração de código

ANALOGIA

Especialidade

Pense em Claude como um analista cuidadoso: respostas estruturadas, segue regras com rigor e lida bem com documentos longos e diretrizes detalhadas.

Meta Llama

Definição

- Família de modelos da Meta com pesos abertos, disponível também via Bedrock
- Equilíbrio competitivo entre tamanho, qualidade e custo, com suporte multilíngue
- Opções de tamanho variam de modelos pequenos a versões maiores em paralelo
- Adotado em ambientes corporativos por permitir personalização avançada
- No Bedrock, é consumido como API gerenciada sem gestão de infraestrutura

Distinção essencial

Aberto

Pesos abertos permitem fine-tuning fora do Bedrock também

Modelo

Via Bedrock, AWS cuida de hospedagem, segurança e escalabilidade

Amazon Titan

Definição

- Família de modelos fundacionais desenvolvida pela própria AWS, exclusiva no Bedrock
- Inclui modelos para geração de texto, embeddings e geração de imagens
- Treinada com foco em qualidade, segurança e responsabilidade no uso de dados
- Boa relação custo-benefício para tarefas comuns de produtividade e busca
- Pode ser customizada com dados próprios da empresa de forma privada e segura

Variantes

Text

Geração e resumo de textos

Embeddings

Vetores para busca semântica

Image

Geração e edição de imagens

Express

Versão otimizada para custo

Amazon Nova

Definição

- Nova geração de modelos fundacionais da AWS, com foco em multimodalidade e custo
- Trabalha com texto, imagem e vídeo de forma integrada em uma mesma família
- Variantes otimizadas para diferentes pontos de equilíbrio entre custo e qualidade
- Acessível via Bedrock como qualquer outro modelo, com a mesma API e ferramentas
- Permite combinar diferentes mídias em um mesmo fluxo de inferência

VARIANTES × NOVA

Micro

Treinamento: Mais rápida e econômica

Inferência: Texto puro com baixo custo

Lite

Treinamento: Equilíbrio entre custo e qualidade

Inferência: Multimodal econômica

Pro

Treinamento: Maior qualidade da família

Inferência: Casos exigentes e multimodais

Como escolher um modelo do Bedrock

Definição

- A escolha depende de tarefa, idioma, contexto necessário, custo e latência aceitável
- Para tarefas com documentos longos, modelos com janela de contexto ampla são ideais
- Para volumes altos com baixo custo, considere variantes pequenas como Titan Express
- Para casos críticos de raciocínio, escolha modelos de maior qualidade da família
- Sempre teste mais de um modelo no mesmo conjunto de prompts antes de decidir

M Ó D U L O

04

Bedrock Playground

Ambiente interativo dentro do Bedrock para experimentar modelos e prompts antes de integrar

O que é o Bedrock Playground?

Definição

- Ambiente interativo dentro da console do Bedrock para testar modelos sem código
- Permite experimentar prompts antes de investir em integração na aplicação
- Suporta ajuste rápido de parâmetros como temperatura, top-p e máximo de tokens
- Ideal para iterar prompts em ciclos curtos com modelos diferentes em paralelo
- Não substitui testes automatizados, mas acelera muito o aprendizado inicial do time

Testar

Testar prompts e modelos sem escrever código de integração

Comparar

Comparar resultados entre modelos para a mesma entrada

Recursos do Playground

Definição

- Interface visual na console com seleção rápida de modelo e parâmetros
- Modos de chat e completion para diferentes estilos de interação
- Ajuste de temperatura, top-p, máximo de tokens e prompt do sistema
- Histórico de conversa preservado durante a sessão para iterar prompts
- Exporta amostras como exemplo de chamada para CLI, SDK ou notebook

Quando usar e limitações

Quando usar

- Validar ideias de prompts antes de investir em código de integração
- Comparar modelos e parâmetros para escolher o mais adequado
- Demonstrar capacidades dos modelos para stakeholders e times de produto
- Treinar prompt engineers e onboard novos integrantes do time de IA
- Documentar casos de teste com prompts e respostas reais para revisão

Limitações

- Não substitui testes automatizados em pipelines de produção
- Sessão é interativa e individual, sem versionamento entre execuções
- Cada chamada consome tokens e gera custo na conta como qualquer invocação
- Modelos disponíveis dependem de habilitação prévia na conta AWS
- Não avalia automaticamente qualidade ou segurança das respostas geradas

M Ó D U L O

05

Capacidade Sob-demanda

Modalidade padrão de consumo do Bedrock, com cobrança por token e sem reserva prévia

O que é capacidade sob-demanda?

Definição

- Modalidade padrão do Bedrock, em que cada chamada é cobrada por tokens consumidos
- Não exige reserva nem compromisso de uso mínimo na conta AWS
- Custo varia conforme tokens de entrada e saída, com preços diferentes por modelo
- Latência sujeita à fila compartilhada do serviço durante picos de demanda
- Quotas regionais limitam total de tokens por minuto disponíveis para a conta

Características da sob-demanda

Aspecto	Vantagem	Cuidado
Compromisso	Sem reserva nem contrato mínimo	Quotas regionais podem limitar pico
Cobrança	Pago apenas pelo que foi consumido	Custo unitário mais alto que provisionada
Latência	Adequada para uso intermitente	Pode oscilar com tráfego concorrente
Onboarding	Disponível imediatamente após habilitar	Sem etapa de provisionamento prévio
Caso típico	Provas de conceito e cargas variáveis	Aplicações com demanda imprevisível

Quando usar a sob-demanda?

Provas de conceito

Validar ideias e protótipos sem assumir compromisso financeiro

Tráfego variável

Aplicações com volume imprevisível ou sazonal ao longo do dia

Volume baixo

Cargas pequenas em que provisionar capacidade não compensa o custo

Equipes pequenas

Times sem dedicado MLOps que precisam começar com mínimo overhead

Múltiplos modelos

Quando há experimentação contínua entre modelos diferentes

M Ó D U L O

06

Capacidade Provisionada

Modalidade do Bedrock com throughput reservado, ideal para tráfego previsível e alto volume

O que é capacidade provisionada?

Definição

- Modalidade em que o cliente reserva throughput dedicado em unidades de modelo
- Compromisso de uso por hora ou por períodos de um e seis meses
- Garante latência consistente e capacidade independente de outras contas
- Costuma ter custo total menor em volumes elevados e previsíveis
- Permite usar modelos customizados via fine-tuning na própria conta

RESERVA

Provisionada

Modalidade do Bedrock em que o cliente reserva throughput dedicado por hora ou por períodos contratados, garantindo latência consistente e capacidade exclusiva.

Como configurar capacidade provisionada

Definição

- Selecionar o modelo desejado dentro do catálogo do Bedrock
- Definir o número de unidades de modelo conforme necessidade prevista
- Escolher o prazo de compromisso entre 1, 6 meses ou sob demanda especial
- Confirmar contrato e custo total estimado antes da ativação do recurso
- A unidade fica disponível para a conta exclusivamente até o fim do contrato

Quando usar capacidade provisionada

- Aplicações com volume previsível e alto durante períodos extensos do dia
- Cargas de produção que exigem latência consistente independentemente de picos
- Casos em que modelos customizados precisam estar sempre disponíveis sem fila
- Cenários em que custo unitário do token sob-demanda já não é viável
- Negócios com pico previsível concentrado em horários definidos do dia

Ideia central

Provisionada compensa quando o tráfego é alto, previsível e exige latência consistente em produção.

Antes de provisionar, valide o padrão de uso real durante semanas em modalidade sob-demanda.

M Ó D U L O

07

Comparação e Escolha

Como decidir entre sob-demanda e provisionada para o seu caso de uso

Sob-demanda x Provisionada

Definição

- Sob-demanda cobra por token consumido sem qualquer compromisso de uso
- Provisionada reserva throughput dedicado por hora, ou por períodos contratados
- Sob-demanda é ideal para experimentação e cargas variáveis no curto prazo
- Provisionada é ideal para produção previsível com alto volume e latência crítica
- A escolha errada pode aumentar custo total ou comprometer a experiência do usuário

Como escolher a modalidade

Padrão de tráfego

Tráfego previsível e estável favorece provisionada, oscilante prefere sob-demanda

Volume previsto

Volumes altos justificam o investimento em capacidade reservada por contrato

Latência exigida

SLA estrito de latência consistente pede provisionada, sem fila concorrente

Modelos customizados


Modelos próprios via fine-tuning costumam exigir capacidade provisionada

Encontrando o ponto de equilíbrio

Definição

- Comece com sob-demanda em provas de conceito e cargas iniciais sem compromisso
- Monitore custo por mês e número de tokens consumidos pela aplicação em produção
- Compare cenários de provisionamento com base no consumo médio observado
- Quando custo unitário sob-demanda passar a doer, migre para capacidade provisionada
- Modalidade pode ser revisada periodicamente conforme padrão de uso evoluir

Padrão de uso



Recapitulando os conceitos da aula

- Dívida técnica em ML acumula em código, dados e modelos ao mesmo tempo
- Boas práticas de MLOps são a forma estruturada de pagar dívida técnica em IA
- Amazon Bedrock dá acesso gerenciado a modelos fundacionais via API
- Catálogo do Bedrock inclui Claude, Llama, Titan, Nova e outros modelos
- Bedrock Playground acelera prototipagem e comparação de prompts e modelos
- Capacidade sob-demanda cobra por token e é ideal para tráfego variável
- Capacidade provisionada reserva throughput para volume previsível e alto
- Modalidade pode ser revisada conforme padrão de uso muda ao longo do projeto