


Governança e Segurança em sistemas responsáveis de IA



Amazon A2I, Service Cards, APIs de moderação, Security Scoping Matrix, linhagem de dados

Agenda

01 A2I e Explicabilidade

Revisão humana e ferramentas para explicar decisões

02 Service Cards e Trade-offs

Documentação de modelos AWS e equilíbrio com interpretabilidade

03 Moderação e Segurança

APIs de moderação e Generative AI Security Scoping Matrix

04 Linhagem e Engenharia

Citação de fontes e boas práticas de engenharia de dados segura

M Ó D U L O

01

Amazon A2I e Explicabilidade


Inserindo revisão humana em fluxos de IA e ferramentas para explicar decisões dos modelos

O que é Amazon A2I?

Definição

- Amazon Augmented AI, serviço gerenciado para incluir revisão humana em pipelines de IA
- Permite enviar previsões de baixa confiança para revisão humana de forma automática
- Integra-se a serviços como Textract, Rekognition, Comprehend e endpoints SageMaker
- Inclui interface pronta para revisores e fluxos de trabalho configuráveis

Fluxo do A2I



Ferramentas de explicabilidade

Definição

- Conjunto de técnicas para entender como modelos chegam a suas decisões
- Algumas explicam o modelo todo; outras explicam decisões individuais
- Não substituem auditoria humana, mas dão suporte para revisões e investigações
- Cada técnica tem custo computacional e nível de confiabilidade próprios

SHAP

Atribui contribuição de cada feature usando teoria de jogos cooperativos

LIME

Aproxima localmente o modelo complexo por um modelo simples interpretável

Importância de features

Mede impacto global de cada feature no desempenho geral do modelo

Quando usar revisão humana

Definição

- Casos com baixa confiança devolvida pelo modelo precisam de validação humana
- Domínios sensíveis como saúde, jurídico e financeiro exigem revisão por padrão
- Auditoria periódica de amostras aleatórias para validar qualidade do modelo
- Coleta de feedback humano para melhorar o modelo com retreinamento posterior
- Resultados marginais que afetam decisões importantes de negócio em escala

DESTAQUE

HITL

Amazon A2I é a opção certa quando o time precisa de revisão humana integrada a serviços de IA da AWS sem construir infraestrutura própria.

Amazon A2I vs SageMaker Ground Truth

Amazon A2I

- Foco em revisão humana de previsões em produção (HITL)
- Integra com Textract, Rekognition, Comprehend e endpoints SageMaker
- Aciona revisão por baixa confiança ou amostragem aleatória
- Workforce: equipe privada, fornecedores ou Mechanical Turk
- Cobrança por previsão revisada, sem infraestrutura para gerenciar

SageMaker Ground Truth

- Foco em rotulagem de datasets antes do treinamento do modelo
- Suporta imagem, texto, vídeo, áudio, ponto 3D e dados tabulares
- Active learning reduz custo rotulando só amostras incertas
- Workforce idêntico ao A2I, mais opção Ground Truth Plus gerenciado
- Cobrança por objeto rotulado, ideal para grandes volumes iniciais

Casos de uso reais do Amazon A2I

Documentos médicos

Classificação automática validada por especialistas quando confiança fica baixa.

Análise financeira

Extração de dados de contratos e notas com revisão por compliance e jurídico.

Moderação de conteúdo

Casos ambíguos de imagens ou texto enviados a revisores humanos treinados.

Sinistros de seguro

Documentos e fotos triados pela IA e validados por peritos antes da liberação.

M Ó D U L O

02

Service Cards e Trade-offs

Documentação dos modelos da AWS e equilíbrio entre desempenho e interpretabilidade

AWS AI Service Cards

Definição

- Documentos públicos da AWS que descrevem casos de uso e limitações dos serviços de IA
- Descrevem casos previstos, casos não recomendados e considerações de design
- Trazem informações sobre dados de treino, métricas de desempenho e equidade
- Cobertura inclui Rekognition, Textract, Comprehend, Transcribe e outros serviços
- Leitura recomendada antes de adotar qualquer serviço de IA da AWS em produção

Performance x Interpretabilidade

1

Modelos simples

Regressão linear e árvores rasas: alta interpretabilidade e baixa performance

2

Modelos médios

Random forest e gradient boosting: equilíbrio razoável entre os dois lados

3

Deep learning

Alta performance em padrões complexos, mas com baixa interpretabilidade nativa

4

Decisão

Use modelo mais simples possível que atinja a métrica mínima exigida pelo negócio

Em domínios regulados, interpretabilidade pode pesar mais que pontos extras de acurácia

Como aplicar service cards

Antes da escolha

Ler o card antes de escolher um serviço para validar adequação ao caso.

Durante o design

Considerar limites declarados no design da arquitetura final da solução.

Em produção

Comparar comportamento real do serviço com casos previstos no card.

Em revisões

Rer o card em revisões periódicas, especialmente em mudanças de versão.

M Ó D U L O

03

Moderação e Segurança

APIs de moderação e Generative AI Security Scoping Matrix para sistemas seguros

Cinco conceitos sobre segurança

01	02	03	04	05
Moderação	Guardrails	Toxicidade	Prompt injection	Scoping
Processo de filtrar conteúdos inapropriados gerados ou consumidos pela IA	Limites técnicos que impedem o modelo de gerar saídas indesejadas	Conteúdo ofensivo, agressivo ou prejudicial que pode aparecer em saídas	Ataque em que entrada manipula o modelo a ignorar instruções originais	Mapeamento de responsabilidades de segurança conforme nível de uso da IA

APIs de moderação

Definição

- Serviços que classificam e filtram conteúdos automaticamente em pipelines de IA
- Amazon Comprehend detecta toxicidade, PII e tópicos sensíveis em texto
- Amazon Rekognition modera imagens e vídeos identificando conteúdo impróprio
- Bedrock Guardrails aplicam filtros configuráveis em entradas e saídas de LLMs
- Uso combinado dessas APIs reduz risco de exposição a conteúdo problemático

ANALOGIA

Filtro

Pense em APIs de moderação como filtros de água: removem contaminantes antes de chegarem ao usuário e antes que saídas problemáticas voltem ao sistema.

Generative AI Security Scoping Matrix

Definição

- Framework da AWS que ajuda a entender responsabilidades de segurança em IA generativa
- Define cinco escopos, do uso de apps de consumo até treinar modelos próprios
- Cada escopo tem distribuição diferente de responsabilidade entre cliente e provedor
- Quanto mais customizado o uso, mais responsabilidades caem sobre o cliente final
- Identificar o escopo correto é essencial para definir controles de segurança aplicáveis

Os cinco escopos da Scoping Matrix

01	02	03	04	05
Escopo 1	Escopo 2	Escopo 3	Escopo 4	Escopo 5
App de IA generativa consumidor: responsabilidade quase toda do fornecedor	App empresarial pronto: cliente cuida de dados, identidade e configurações	App de terceiros com API: você integra, cuida de dados e prompt injection	Modelo pré-treinado customizado: fine- tuning amplia responsabilidade do cliente	Modelo próprio treinado: cliente é responsável por quase toda a stack de segurança

M Ó D U L O

04

Linhagem e Engenharia Segura

Citação de fontes, linhagem de dados e boas práticas de engenharia de dados segura

Citação de fontes e linhagem

Definição

- Citação de fontes mostra ao usuário a origem das informações em cada resposta gerada
- Aumenta confiança nas respostas e permite verificação manual das informações
- Linhagem de dados rastreia todo o caminho desde a fonte até o modelo treinado
- Combinadas, dão visibilidade completa para auditoria, compliance e governança
- Sem essas práticas, sistemas de IA viram caixas-pretas sem possibilidade de auditoria

Citar

Indicar fontes utilizadas para gerar cada resposta

Rastrear

Documentar todo o caminho dos dados até o modelo

Linhagem de dados

Definição

- Linhagem de dados é o histórico completo de origem e transformações dos dados
- Permite identificar quais fontes alimentaram o modelo treinado em cada versão
- Essencial para auditoria, compliance e investigação de incidentes em produção
- Bedrock Knowledge Bases já entregam citação automática nas respostas geradas
- Sem linhagem clara, é impossível responder a pedidos de remoção de dados

Engenharia de dados segura

Boas práticas

- Criptografar dados em repouso e em trânsito em todos os pontos do pipeline
- Aplicar princípio do menor privilégio em acessos a buckets, bancos e modelos
- Anonimizar e remover dados pessoais antes de usá-los em treinamento de modelos
- Versionar dados, modelos e códigos de transformação para rastreabilidade total
- Auditar acessos e mudanças com CloudTrail e logs centralizados em tempo real

A evitar

- Acessos amplos a dados sensíveis sem justificativa registrada
- Pipelines sem testes de integridade dos dados de entrada
- Treinar modelos diretamente com dados pessoais sem anonimização prévia
- Compartilhar conjuntos de treino sem controle de versão ou origem
- Ignorar requisitos de compliance setoriais e regulatórios aplicáveis

LGPD e GDPR aplicadas à IA

LGPD (Brasil)

- Lei 13.709 regula tratamento de dados pessoais no Brasil desde 2020
- Exige base legal explícita para usar dados pessoais em treinamento de modelos
- Garante direito à explicação em decisões automatizadas que afetam o titular
- Permite revisão de decisões automatizadas por humano quando solicitada pelo titular
- ANPD (Autoridade Nacional) pode aplicar multas de até 2% do faturamento limitado a 50M

GDPR (UE)

- Regulamento (UE) 2016/679, referência global em proteção de dados desde 2018
- Define seis bases legais e exige avaliação de impacto para IA de alto risco
- AI Act complementa o GDPR classificando sistemas por nível de risco aplicado
- Inclui direito ao esquecimento e oposição a decisões totalmente automatizadas
- Multas chegam a 4% do faturamento global anual ou 20 milhões de euros, o maior valor

Recapitulando os conceitos da aula

- Amazon A2I integra revisão humana em pipelines para casos de baixa confiança
- SHAP, LIME e importância de features explicam decisões de modelos opacos
- AWS AI Service Cards documentam casos previstos e limites dos serviços de IA
- Trade-off entre performance e interpretabilidade exige escolhas conscientes
- APIs de moderação filtram conteúdo tóxico, PII e respostas inadequadas
- Generative AI Security Scoping Matrix mapeia responsabilidades em cinco escopos
- Citação de fontes e linhagem garantem rastreabilidade e atendem compliance
- Engenharia de dados segura combina criptografia, mínimo privilégio e auditoria

P e r g u n t a 1

Uma equipe está construindo um sistema de classificação de documentos médicos e precisa garantir que casos de baixa confiança do modelo sejam revisados por especialistas humanos antes da decisão final. Qual serviço da AWS é mais adequado?

- (A) SageMaker Model Monitor para detectar drift
- (B) Amazon A2I para revisão humana automatizada
- (C) Bedrock Guardrails para filtrar conteúdo gerado
- (D) AWS AI Service Cards para documentar limites

P e r g u n t a 1

Uma equipe está construindo um sistema de classificação de documentos médicos e precisa garantir que casos de baixa confiança do modelo sejam revisados por especialistas humanos antes da decisão final. Qual serviço da AWS é mais adequado?

- (A) SageMaker Model Monitor para detectar drift
- (B) Amazon A2I para revisão humana automatizada**
- (C) Bedrock Guardrails para filtrar conteúdo gerado
- (D) AWS AI Service Cards para documentar limites

P e r g u n t a 3

Uma empresa decidiu fazer fine-tuning do Claude no Bedrock com seus próprios dados de atendimento. Em qual escopo da Generative AI Security Scoping Matrix essa configuração se encaixa?

- (A) Escopo 1 — uso de aplicativo de IA generativa pronto
- (B) Escopo 3 — aplicativo de terceiros consumido via API
- (C) Escopo 4 — modelo pré-treinado com fine-tuning próprio
- (D) Escopo 5 — modelo treinado do zero pela empresa

P e r g u n t a 3

Uma empresa decidiu fazer fine-tuning do Claude no Bedrock com seus próprios dados de atendimento. Em qual escopo da Generative AI Security Scoping Matrix essa configuração se encaixa?

- (A) Escopo 1 — uso de aplicativo de IA generativa pronto
- (B) Escopo 3 — aplicativo de terceiros consumido via API
- (C) Escopo 4 — modelo pré-treinado com fine-tuning próprio**
- (D) Escopo 5 — modelo treinado do zero pela empresa