

Tuning, Métricas MLOps e Operação de Modelos

Encontro 13 — Guia Completo de Estudos para AWS AI Practitioner (Foco no Exame)

Instrutora Josely Castro

Instrutora Josely Castro

Tuning e AutoML no SageMaker

Estudo aprofundado sobre HPO (Hyperparameter Optimization), SageMaker Autopilot para dados tabulares e estratégias de Adaptação de Domínio.

1. Hyperparameter Optimization (HPO) e Parâmetros

Para o exame de certificação, é fundamental entender a linha divisória matemática entre Parâmetros e Hiperparâmetros. Em modelos de machine learning, os Parâmetros (parameters) representam os valores internos ajustados automaticamente pelo próprio algoritmo através de otimizações de gradiente (ex: pesos w e vieses b de neurônios). Os Hiperparâmetros (hyperparameters), ao contrário, são coeficientes de controle definidos externamente e fixados antes do treinamento começar.

Atributo	Parâmetro do Modelo	Hiperparâmetro do Modelo
Definição	Variável interna que o modelo aprende a partir dos dados durante o treino.	Variável externa definida pelo desenvolvedor para controlar o algoritmo.
Exemplos Práticos	Pesos de conexões neurais, coeficientes de regressão linear, nós de árvores de decisão.	Taxa de aprendizado, número de épocas, tamanho de batch, profundidade máxima da árvore.
Método de Ajuste	Calculado de forma matemática via algoritmos como Backpropagation ou Gradiente Descendente.	Definido por métodos sistemáticos de busca gerenciados (tuning jobs do HPO).

Análise Matemática dos Métodos de Busca de HPO

O SageMaker suporta três principais estratégias de busca, com diferentes trade-offs econômicos e de precisão:

- **Grid Search (Busca em Grade):** Testa exaustivamente todas as combinações matemáticas possíveis em uma grade de coordenadas definida. Se você define N hiperparâmetros com M valores possíveis cada, o número de execuções de treino é M elevado a N . Possui altíssimo custo computacional e baixa eficiência, sendo redundante em muitos cenários.
- **Random Search (Busca Aleatória):** Sorteia aleatoriamente combinações no espaço de busca. A probabilidade matemática de encontrar uma ótima combinação é alta mesmo com poucas tentativas, pois ela não fica presa em sub-regiões inflexíveis da grade. É muito mais rápida que a busca em grade.
- **Bayesian Optimization (Otimização Bayesiana):** O método mais avançado e recomendado. Ele modela matematicamente o problema de busca como um processo gaussiano (Gaussian Process). A cada nova execução de treino, o algoritmo recalcula a probabilidade de ganho de desempenho baseado nos resultados históricos anteriores (função de aquisição). Isso direciona a busca para as áreas mais promissoras, otimizando o tempo e reduzindo os custos dos recursos computacionais da AWS.

ANALOGIA

A Busca pelo Tesouro:

Imagina que você quer achar um tesouro enterrado em um terreno de 100x100 metros.

- **Grid Search:** Cava buracos sequenciais de 1 em 1 metro, gastando dias de trabalho pesado de forma burra.
- **Random Search:** Joga dardos de olhos vendados e cava onde eles caírem. Acha o tesouro mais rápido por sorte estatística.
- **Otimização Bayesiana:** Usa um detector de metal. Cada apito do aparelho (treino anterior) te diz se você está mais perto ou longe, guiando seus passos inteligentes diretamente para o ponto exato.

REGRA DE OURO PARA PROVAS

Para o exame AWS AI Practitioner: Se a questão exigir maximizar a precisão do modelo ao mesmo tempo que gerencia e otimiza o orçamento computacional dos jobs de treinamento, escolha a Otimização Bayesiana (Bayesian Optimization).

2. SageMaker Autopilot (AutoML)

O SageMaker Autopilot automatiza todo o pipeline de ponta a ponta: engenharia de dados (data preprocessing), seleção de algoritmos e tuning de hiperparâmetros.

Um detalhe crucial para a prova é a Transparência do Autopilot (Autopilot Transparency). Ao invés de agir como uma caixa preta inacessível, o Autopilot gera automaticamente dois notebooks documentados:

- Notebook de Exploração de Dados: Analisa o dataset para identificar dados ausentes, duplicados ou distribuições desequilibradas.
- Notebook de Candidatos a Modelo: Contém o código Python em SageMaker SDK que descreve todas as receitas de processamento e algoritmos testados, permitindo que o time de engenharia assuma o controle do código e faça ajustes manuais.

3. Ajuste Fino com Adaptação de Domínio

A Adaptação de Domínio (Domain Adaptation) adapta um Foundation Model (FM) geral a um vocabulário corporativo de nicho. Na prática do mercado de trabalho, essa abordagem impede alucinações e garante conformidade.

Exemplo Real de Mercado

Uma grande instituição de saúde adaptou um modelo Llama-3 de uso geral. O modelo geral interpretava a sigla médica 'IAM' como 'Inteligência Artificial em Medicina'. Após o processo de Adaptação de Domínio com dados clínicos corporativos, o modelo aprendeu corretamente que, no contexto hospitalar da instituição, 'IAM' significa 'Infarto Agudo do Miocárdio'.

Redução de Dimensionalidade

Simplificação estrutural de conjuntos de dados. Análise das abordagens lineares e não-lineares, com analogia fotográfica e espacial.

A Matemática da Redução de Dimensionalidade

Quando temos tabelas com centenas de colunas ou embeddings vetoriais com milhares de dimensões, os modelos de ML enfrentam a 'maldição da dimensionalidade' (curse of dimensionality), o que aumenta a latência de busca e facilita a ocorrência de overfitting. Reduzir dimensionalidade é essencial para simplificar e acelerar previsões.

Análise Matemática das Técnicas

1. PCA (Principal Component Analysis)

Técnica linear clássica. Ela realiza uma transformação ortogonal dos dados para um novo sistema de coordenadas. O primeiro componente principal captura a maior variabilidade possível dos dados (variância), e cada componente subsequente captura a maior variabilidade restante sob a restrição de ser ortogonal (perpendicular) aos componentes anteriores.

ANALOGIA

A Sombra da Câmera (PCA):

Imagina que você quer tirar uma fotografia 2D de uma pipa flutuando no ar em 3D. Se você tirar a foto com a câmera posicionada exatamente em cima, a pipa parecerá um traço plano e você perderá a largura e a cauda. O PCA é a matemática que move a sua câmera no espaço até achar a angulação perfeita que projeta a sombra mais informativa da pipa na parede 2D, preservando o máximo de detalhes possível da forma original.

2. t-SNE (t-Distributed Stochastic Neighbor Embedding)

Algoritmo não-linear focado na preservação de relações de vizinhança local. Ele converte distâncias euclidianas entre pontos em probabilidades condicionais que representam similaridades. Ele é excelente para agrupar e visualizar clusters de embeddings em 2D ou 3D, mas altera a estrutura de distâncias globais.

3. UMAP (Uniform Manifold Approximation and Projection)

Algoritmo moderno não-linear baseado em geometria riemanniana. Diferente do t-SNE, o UMAP consegue preservar tanto as relações locais (vizinhos mais próximos) quanto a estrutura global do dataset. Além disso, a sua formulação matemática o torna muito mais rápido, sendo a escolha ideal para datasets massivos com milhões de vetores.

4. Autoencoders

Redes neurais artificiais compostas por duas partes principais: o encoder, que mapeia a entrada X de alta dimensão para um espaço latente compactado Z (gargalo), e o decoder, que tenta reconstruir o sinal original a partir de Z. A rede é treinada minimizando o erro de reconstrução, forçando Z a conter a essência matemática dos dados.

RESUMO

Resumo de Engenharia para Prova:

- **Visualização de Embeddings de Palavras:** Use t-SNE ou UMAP.
- **Compressão Linear Rápida e Simples:** Use PCA.
- **Compactação Não-Linear Complexa:** Use Autoencoders.

Métricas para Foundation Models

Como avaliar objetivamente o desempenho de LLMs e FMs. Detalhamento matemático de precisão, recall e similaridade por vetores.

Matemática das Métricas de Texto

Avaliar textos gerados livremente por LLMs exige métricas robustas. Para o exame, você deve entender como cada uma funciona matematicamente:

1. BLEU (Bilingual Evaluation Understudy)

Focada em precisão de termos exatos. Ela calcula a proporção de n-gramas do texto gerado que aparecem no texto de referência. Para evitar que modelos gerem respostas curtas e incompletas para inflar a nota, o BLEU multiplica o resultado final por um fator de correção chamado Penalidade de Brevidade (Brevity Penalty - BP).

DEFINIÇÃO

Matemática do BLEU:

$BP = 1$ se o tamanho da geração for maior ou igual ao da referência. Caso contrário, $BP = \exp(1 - r / c)$, onde r é o tamanho da referência e c o da geração. O score final é a multiplicação de BP pela média geométrica dos scores de precisão de n-gramas.

ANALOGIA

O Corretor Rígido:

Imagine um professor corrigindo uma prova com um gabarito rígido ao lado. Se o gabarito diz 'A casa é amarela' e o aluno escreve 'A residência é amarela', o professor dá zero para a palavra 'residência' porque ela não está escrita exatamente igual no gabarito, ignorando que o significado é o mesmo.

2. ROUGE (Recall-Oriented Understudy for Gisting Evaluation)

Focada em recall (cobertura). Ela quer saber quanto do conteúdo essencial da referência humana foi de fato gerado pelo modelo no resumo.

A variante ROUGE-L usa a Subsequência Comum Mais Longa (LCS). Ela identifica a sequência mais longa de palavras comuns entre os dois textos que aparece na mesma ordem relativa, mesmo que existam palavras intermediárias não-comuns.

DEFINIÇÃO

Matemática do ROUGE-L:

$Recall_L = LCS(\text{Geração}, \text{Referência}) / \text{Total_palavras}(\text{Referência})$

$Precisão_L = LCS(\text{Geração}, \text{Referência}) / \text{Total_palavras}(\text{Geração})$

O ROUGE-L é o F-Score calculado a partir dessas duas frações.

ANALOGIA

A Lista de Compras:

Imagine que seu cônjuge te deu uma lista de compras com 10 itens (Referência). Você vai ao mercado e volta com o carrinho cheio (Geração). O ROUGE é o fiscal que confere: 'Dos 10 itens que estavam na lista, quantos você trouxe?'. Se você trouxe 8, seu ROUGE (Recall) é 80%, mesmo que você tenha trazido outras 20 coisas extras no carrinho.

3. BERTScore

A métrica semântica moderna. Em vez de fazer casamento exato de strings (letras e palavras), ela converte cada palavra da geração e da referência em embeddings vetoriais contextuais (usando o BERT). Em seguida, ela calcula a similaridade de cosseno (o cosseno do ângulo entre os dois vetores no espaço multidimensional) para cada par de palavras. Palavras com significados

próximos possuem vetores apontando quase na mesma direção, resultando em um cosseno próximo a 1.

ANALOGIA

O Cupido Semântico:

O BERTScore funciona como um aplicativo de relacionamentos. Ele não olha se as palavras se vestem igual (letras escritas), mas sim se a 'vibração e energia interna' (significado) são compatíveis. Ele percebe imediatamente que 'cachorro' e 'cão' têm a mesma sintonia interna e dá nota 10 para o par, mesmo que a escrita seja diferente.

Implantação de Modelos

Arquitetura de Endpoints do SageMaker. Latência, escalabilidade automatizada e a escolha correta do padrão de hospedagem.

Decisões de Arquitetura de Deploy para a Certificação

Na prova AWS AI Practitioner, haverá cenários específicos cobrando a escolha correta de infraestrutura de inferência com base no custo, latência e comportamento do tráfego:

- Real-time Endpoints (Hospedagem em Tempo Real): Recomendado para aplicações interativas com tráfego contínuo e exigência de baixíssima latência (milissegundos). Requer provisionamento persistente de instâncias EC2 rodando 24/7.
- Serverless Endpoints (Pontos sem Servidor): Perfeito para tráfego esporádico ou intermitente com picos imprevisíveis. Você não paga nada pelo tempo ocioso da máquina. A desvantagem são os potenciais atrasos de 'inicialização a frio' (cold start) quando o contêiner precisa ser criado do zero após inatividade.
- Asynchronous Endpoints (Inferência Assíncrona): Para cargas de trabalho com requisições grandes (imagens médicas ou vídeos pesados) que levam minutos para processar. Possui uma fila interna baseada no Amazon SQS e permite escalar as instâncias de processamento até zero se não houver requisições na fila.
- Batch Transform (Transformação em Lote): Para processamento offline não-interativo de datasets massivos armazenados no Amazon S3. Não requer endpoints persistentes ativos, reduzindo drasticamente custos recorrentes.

REGRA DE OURO PARA PROVAS

Palavras-Chave de Questão:

- *Tráfego intermitente / Desejo de custo zero quando ocioso: Serverless Endpoint.*
- *Baixa latência e tráfego persistente: Real-time Endpoint.*
- *Processar arquivos gigantescos de forma não-síncrona/lote: Batch Transform.*

MLOps e Experimentos

A governança do ciclo de vida de ML. Gerenciamento de desvios e rastreabilidade com SageMaker Pipelines.

A Governança de MLOps no Exame

No exame de certificação, entenda que o MLOps resolve a falta de governança e de controle de qualidade sobre modelos implantados.

Os Diferentes Componentes do SageMaker para MLOps

- SageMaker Pipelines: O primeiro serviço de CI/CD nativo de ML. Permite construir, automatizar e gerenciar pipelines de treinamento e deploy como código, garantindo reprodutibilidade.
- SageMaker Experiments: Usado para organizar, rastrear e comparar execuções de treinamento (trials). Registra metadados como hiperparâmetros, dados de entrada utilizados, curvas de perda e acurácia.
- SageMaker Model Registry: Catálogo centralizado de modelos. Permite registrar versões do modelo, gerenciar seu ciclo de vida de aprovação (Pendente -> Aprovado -> Rejeitado) e facilitar a promoção para produção.

REGRA DE OURO PARA PROVAS

Diferença Crítica MLOps vs DevOps: DevOps gerencia apenas código estático. MLOps precisa gerenciar código, infraestrutura e o desvio contínuo dos dados estatísticos no tempo (Data e Model Drift).

SageMaker DeepAR

Previsão estatística probabilística com Deep Learning. Redes recorrentes e previsões baseadas em P10, P50 e P90.

A Matemática Probabilística do DeepAR

Diferente de modelos clássicos que calculam previsões determinísticas pontuais (ex: 'amanhã venderemos 100 refrigerantes'), o SageMaker DeepAR é baseado em Redes Neurais Recorrentes (RNN) e estima uma distribuição de probabilidade sobre o futuro.

Ele calcula previsões probabilísticas chamadas quantis (quantiles), que representam margens de confiança estatística:

- P10: Cenário pessimista ou subestimado. Há apenas 10% de chance de a demanda real ser menor que esse valor.
- P50: Cenário mediano. Há 50% de chance de a demanda real ser maior ou menor (mediana).
- P90: Cenário otimista ou de pico de demanda. Há 90% de chance de a demanda real ser menor que esse valor (ou apenas 10% de chance de ser maior).

DEFINIÇÃO

Por que prever com quantis?

Para controle de estoque em um supermercado, prever apenas a mediana (P50) significa que em 50% dos dias faltará produto nas prateleiras. Planejar compras baseando-se no quantil de segurança P90 garante que o mercado terá estoque suficiente para cobrir picos de vendas em 90% dos cenários, evitando ruptura de estoque.

ANALOGIA

A Previsão do Clima Probabilística:

Dizer 'Amanhã vai chover exatamente 10mm de água' é uma previsão determinística pontual. Se chover 100mm, a cidade alaga; se não chover nada, o agricultor desperdiça água. Uma previsão probabilística diz: 'A média prevista é 10mm, mas temos 90% de certeza (P90) de que a chuva não passará de 35mm'. Isso dá margem de segurança para a tomada de decisões.

Monitoramento e Retreinamento

Mantendo a saúde do modelo em produção. Detalhamento do SageMaker Model Monitor e das 4 categorias de monitoramento.

O Ciclo do SageMaker Model Monitor

Para o exame de certificação AWS AI Practitioner, memorize as quatro categorias de monitoramento de produção oferecidas pelo SageMaker Model Monitor:

- Monitoramento da Qualidade dos Dados (Data Quality): Detecta o desvio de dados (Data Drift) comparando a distribuição estatística das entradas de produção com a baseline de treinamento.
- Monitoramento da Qualidade do Modelo (Model Quality): Compara as previsões do modelo com os dados reais de gabarito reais (ground truth labels) coletados posteriormente para calcular a perda real de acurácia ou recall.
- Monitoramento do Viés do Modelo (Model Bias Drift): Avalia se o modelo passou a apresentar vieses discriminatórios ou preconceituosos em relação a grupos protegidos (ex: gênero, idade) após receber dados de produção.
- Monitoramento da Atribuição de Features (Feature Attribution Drift): Avalia se a importância relativa que o modelo dá para cada coluna ao tomar decisões mudou no tempo em comparação com o treinamento.

REGRA DE OURO PARA PROVAS

Questão Típica do Exame:

*Se a questão mencionar que a acurácia de um classificador de crédito caiu em produção devido a mudanças no perfil socioeconômico dos proponentes de empréstimo, a causa raiz é o **Data Drift** (Desvio de Dados), e o serviço AWS usado para capturar isso automaticamente é o **SageMaker Model Monitor**.*

Glossário Consolidado do Encontro 13

Termo em Inglês	Tradução Sugerida	Definição Resumida para o Exame
Hyperparameter Optimization (HPO)	Otimização de Hiperparâmetros	Busca automatizada da melhor combinação de configurações externas do modelo.
SageMaker Autopilot	SageMaker Autopilot (AutoML)	Serviço que automatiza a criação de modelos tabulares gerando notebooks transparentes.
Domain Adaptation	Adaptação de Domínio	Fine-tuning focado em especializar FMs em jargões de setores como saúde e finanças.
Dimensionality Reduction	Redução de Dimensionalidade	Técnicas de simplificação de dados para reduzir custos e evitar overfitting.
BLEU	Avaliação Substituta Bilíngue	Métrica de precisão baseada em n-gramas exatos, ideal para tradução e insensível a sinônimos.
ROUGE	Avaliação Baseada em Recall de Resumos	Métrica de cobertura (recall) de tokens com foco em avaliar resumos automáticos.
BERTScore	BERTScore	Avaliação semântica via embeddings contextualizados, reconhecendo sinônimos.
Real-time Endpoints	Pontos de Extremidade em Tempo Real	APIs HTTP dedicadas para inferências síncronas de baixíssima latência.
Data Drift	Desvio de Dados	Queda de performance causada pela alteração estatística dos dados em produção.
Concept Drift	Desvio de Conceito	Mudança na relação lógica de causa/efeito entre as features e o alvo do modelo.
SageMaker DeepAR	SageMaker DeepAR	Algoritmo de previsão probabilística de séries temporais baseado em redes neurais.
Model Monitor	Monitor de Modelos do SageMaker	Serviço gerenciado para monitoramento de drift, qualidade e viés em tempo real.

TERMO TÉCNICO: data drift**Tradução:** *desvio de dados***Definição:** Desalinhamento estatístico que ocorre quando os dados fornecidos ao modelo em produção mudam substancialmente em comparação com os dados usados no treinamento, causando a degradação lenta da precisão.**TERMO TÉCNICO: domain adaptation****Tradução:** *adaptação de domínio***Definição:** Técnica de especialização de modelos que ajusta um Foundation Model de uso geral a um segmento específico de mercado, alinhando a linguagem e prevenindo alucinações.

Análise das Questões de Avaliação

QUESTÃO DE AVALIAÇÃO — EXAME PREP

Após implantar um modelo em produção, sua equipe percebe que a precisão caiu com o tempo. Qual prática de MLOps deveria ter sido implementada para detectar e corrigir esse problema?

- (A) Versionamento apenas do código fonte
- (B) Monitoramento contínuo e retreinamento periódico
- (C) Deploy mais rápido do modelo
- (D) Aumentar o número de épocas no treino original

Opção	Veredicto	Análise Detalhada
(A)	INCORRETA	O versionamento do código-fonte é uma boa prática de DevOps/MLOps, mas isoladamente ele não avisa que o modelo em produção está perdendo precisão devido a variações do mundo real, nem corrige a perda de desempenho automaticamente.
(B)	CORRETA	O monitoramento contínuo (ex: SageMaker Model Monitor) compara as inferências em produção com a baseline para avisar sobre desvios de dados. Ao detectar a queda, o retreinamento do modelo com dados recentes corrige a precisão.
(C)	INCORRETA	Fazer o deploy mais rápido do modelo não resolve o problema. Se o modelo implantado continuar usando dados de treino defasados e não for monitorado, a precisão continuará a cair independentemente da velocidade do deploy.
(D)	INCORRETA	Aumentar o número de épocas altera o treinamento inicial do modelo, o que pode levar ao overfitting e não corrige o envelhecimento natural do modelo perante dados novos recebidos após o deploy em produção.

RESPOSTA CORRETA: OPÇÃO (B)

Justificativa com Palavras-Chave:

A perda de precisão gradual em produção é resolvida através de **monitoramento contínuo** (para detectar desvios de dados e desvios de conceito — data drift e concept drift) e **retreinamento periódico** (para atualizar o modelo com os padrões estatísticos mais recentes do negócio).