

Simulado Comentado 01

AWS Certified AI Practitioner • AIF-C01

FUNDAMENTOS • EMBEDDINGS • ML • INFERÊNCIA • MÉTRICAS • EC2 TRN/INF

Uma empresa avalia o ciclo de vida de um modelo de Machine Learning. Sobre as fases de treinamento e inferência, qual afirmação está CORRETA?

- A** Treinamento e inferência têm exatamente o mesmo custo computacional e ocorrem em paralelo.
- B** Inferência ocorre antes do treinamento, gerando os dados que serão usados para aprender.
- C** Treinamento costuma ser pontual e tem custo computacional alto; inferência é contínua e tem custo unitário menor, mas recorrente.
- D** Inferência exige um volume de dados maior que o treinamento, pois é executada milhões de vezes.

Fundamentos — Treinamento vs Inferência

- A) Treinamento e inferência têm exatamente o mesmo custo computacional e ocorrem em paralelo.
- B) Inferência ocorre antes do treinamento, gerando os dados que serão usados para aprender.
- C) Treinamento costuma ser pontual e tem custo computacional alto; inferência é contínua e tem custo unitário menor, mas recorrente.**
- D) Inferência exige um volume de dados maior que o treinamento, pois é executada milhões de vezes.

Por que C é a resposta correta

 Treinamento

- 🕒 O modelo aprende a partir dos dados
- 📅 Acontece uma vez ou em ciclos pontuais
- 📄 Consome muitos dados
- 🖨️ Exige hardware especializado (GPUs / Trainium)

 Inferência

- 🔊 Uso do modelo já treinado para gerar previsões
- 🔄 Acontece continuamente em produção
- 💰 Custo unitário menor, mas recorrente

Treinamento é a fase em que o modelo aprende a partir dos dados geralmente acontece uma vez (ou em ciclos pontuais), consome muitos dados e exige hardware especializado (GPUs/Trainium).

Inferência é o uso do modelo já treinado para gerar previsões: acontece continuamente em produção, com custo unitário menor, mas recorrente.

Fundamentos — Características dos SLMs

Selecione DUAS características que distinguem os SLMs (Small Language Models) dos LLMs (Large Language Models).

A

Possuem ordens de grandeza MENOS parâmetros que os LLMs.

B

São treinados com trilhões de tokens em pré-treinamento massivo.

C

Podem rodar localmente, em servidores menores ou em dispositivos finais (edge).

D

Apresentam latência de inferência maior que os LLMs.

E

Substituem os LLMs em qualquer cenário, sempre com qualidade superior.

Fundamentos — Características dos SLMs



A) Possuem ordens de grandeza MENOS parâmetros que os LLMs.



B) São treinados com trilhões de tokens em pré-treinamento massivo.



C) Podem rodar localmente, em servidores menores ou em dispositivos finais (edge).



D) Apresentam latência de inferência maior que os LLMs.



E) Substituem os LLMs em qualquer cenário, sempre com qualidade superior.

Por que A e C são as respostas corretas



SLMs

alternativas corretas A e C

- ✖ Milhões a poucos bilhões de parâmetros
- 📁 Rodam localmente, em servidores modestos ou em dispositivos finais
- ⚡ Mais rápidos na inferência
- 🛡 Ideais para edge, baixa latência e privacidade
- 📁 Treinados com volumes menores e mais focados



LLMs

- ✖ Dezenas a centenas de bilhões de parâmetros
- ☁ Exigem infraestrutura robusta em nuvem
- 🌐 Superiores em generalização ampla
- 📁 Treinados com volumes massivos de dados

SLMs possuem ordens de grandeza menos parâmetros que os LLMs (A), milhões a poucos bilhões, contra dezenas/centenas de bilhões dos LLMs. Justamente por serem menores, podem rodar localmente, em servidores modestos ou em dispositivos finais (C), ideal para edge, baixa latência e privacidade. As demais são incorretas: SLMs são treinados com volumes menores e mais focados; são **MAIS** rápidos na inferência; e **NÃO** substituem LLMs em qualquer cenário (perdem em generalização ampla).

Qual mecanismo, central na arquitetura Transformer, permite ao modelo decidir quais partes do texto são mais importantes em cada momento, ponderando os tokens anteriores e capturando relações independentemente da distância no texto?

- A** Janela deslizante de convolução.
- B** Mecanismo de atenção (attention).
- C** Backpropagation no tempo (BPTT) das RNNs.
- D** Pooling máximo entre camadas.

Fundamentos — Transformer

- A) Janela deslizante de convolução.
- ✓ B) Mecanismo de atenção (attention).**
- C) Backpropagation no tempo (BPTT) das RNNs.
- D) Pooling máximo entre camadas.

Por que B é a resposta correta

 O que é

- ❖ Componente central do Transformer
- 🔊 Dá mais peso às palavras que mais importam para prever a próxima

 Por que importa

- 📄 Funciona independentemente da distância no texto
- Viabilizou treinar modelos muito maiores em paralelo

O mecanismo de atenção é o componente central do Transformer. Permite ao modelo dar mais peso às palavras que mais importam para prever a próxima, independentemente da distância no texto. Foi essa inovação (publicada em 2017) que viabilizou treinar modelos muito maiores em paralelo e originou os LLMs modernos.

Sobre a distinção entre algoritmo e modelo em Machine Learning, qual afirmação está CORRETA?

A

Algoritmo e modelo são sinônimos: termos diferentes para a mesma coisa.

B

Modelo é o método de treinamento; algoritmo é o resultado final usado em produção.

C

Algoritmo é o conjunto de passos para treinar, modelo é o resultado obtido após aplicar o algoritmo aos dados.

D

Algoritmo só atua na fase de inferência; modelo só atua na fase de treinamento.

Fundamentos — Modelo vs Algoritmo

- A** A) Algoritmo e modelo são sinônimos: termos diferentes para a mesma coisa.
- B** B) Modelo é o método de treinamento; algoritmo é o resultado final usado em produção.
- C** **Algoritmo é o conjunto de passos para treinar, modelo é o resultado obtido após aplicar o algoritmo aos dados.**
- D** D) Algoritmo só atua na fase de inferência; modelo só atua na fase de treinamento.

Por que C é a resposta correta

**Algoritmo**
o método

Conjunto de passos lógicos que define como o modelo será treinado

</> Exemplos: regressão linear, árvores de decisão, gradient boosting

🏠 A receita

**Modelo**
o resultado

📈 Função matemática aprendida que transforma entradas em saídas

🕒 Existe após o treinamento ter sido executado

🍽️ O prato pronto

O algoritmo é o método, o conjunto de passos lógicos que define como o modelo será treinado (ex.: regressão linear, árvores de decisão, gradient boosting). O modelo é o resultado, a função matemática aprendida que transforma entradas em saídas. Pense: receita (algoritmo) vs prato pronto (modelo).

Embeddings

Uma equipe quer construir uma funcionalidade na qual o usuário envia uma descrição em texto ("praia ao pôr do sol") e recebe uma imagem gerada com base nessa descrição. Qual tipo de modelo é o MAIS adequado para essa tarefa?

A

Modelo de embedding de texto.

B

Modelo de embedding multimodal (apenas).

C

Modelo de geração multimodal.

D

Modelo bag-of-words com TF-IDF.

Embeddings

A

A) Modelo de embedding de texto.

B

B) Modelo de embedding multimodal.

✓

C) **Modelo de geração multimodal.**

D

D) Modelo bag-of-words com TF-IDF.

Por que C é a resposta correta**Embedding multimodal**
compara

- ↔ Compara conteúdos de modalidades diferentes
- 🗺 Mapeia texto e imagem em um espaço vetorial comum
- Q Não cria nada novo — mede similaridade

**Geração multimodal**
cria

- ⚡ Cria saída em uma modalidade a partir de outra
- 📦 Exemplo: texto-para-imagem gera algo que não existia
- Entrada em uma modalidade, saída em outra

Embedding multimodal apenas COMPARA conteúdos de modalidades diferentes em um espaço vetorial comum. Geração multimodal CRIA saída em uma modalidade a partir de outra, exatamente o caso de texto-para-imagem. A diferença-chave: embedding compara, geração cria.

Qual a principal função do Amazon Mechanical Turk no contexto de preparação de dados para Inteligência Artificial?

- A Treinar modelos de deep learning em GPUs gerenciadas.
- B Armazenar embeddings em colunas vetoriais consultáveis por SQL.
- C Fornecer força de trabalho humana sob demanda para tarefas como rotulagem, validação e curadoria de dados.
- D Servir endpoints de inferência em tempo real para LLMs.

Rotulagem — Mechanical Turk

- A) Treinar modelos de deep learning em GPUs gerenciadas.
- B) Armazenar embeddings em colunas vetoriais consultáveis por SQL.
- C) Fornecer força de trabalho humana sob demanda para tarefas como rotulagem, validação e curadoria de dados.**
- D) Servir endpoints de inferência em tempo real para LLMs.

Por que C é a resposta correta



O que é
plataforma AWS

👤 Força de trabalho
humana sob
demanda

🕒 Acesso a
trabalhadores
humanos reais,
quando e quanto
precisar



O que fazem
human intelligence
tasks (HITs)

👁 Rotulagem de
dados

✓ Validação de
resultados

🔍 Curadoria —
tarefas que
máquinas fazem
mal



Integração
SageMaker Ground
Truth

⬆⬆ Escala a rotulagem
de dados para
projetos maiores

🔄 Combina revisão
humana com
automação do
SageMaker

Mechanical Turk é uma plataforma da AWS de força de trabalho humana sob demanda. Trabalhadores executam "human intelligence tasks" (HITs), úteis para rotulagem, validação e curadoria, tarefas que máquinas fazem mal. Pode ser integrado ao SageMaker Ground Truth para escalar a rotulagem.

Banco de vetores

Uma aplicação de RAG precisa armazenar embeddings junto com dados estruturados de produtos (preço, categoria, estoque) em um único banco gerenciado da AWS, consultando ambos com SQL. Qual solução é a MAIS adequada?

A Amazon S3 com Athena para consultas em arquivos Parquet.

B Amazon Aurora PostgreSQL com a extensão pgvector.

C Amazon DynamoDB com índices secundários globais.

D Amazon SageMaker Ground Truth para indexar vetores.

Banco de vetores

- A) Amazon S3 com Athena para consultas em arquivos Parquet.
- B) Amazon Aurora PostgreSQL com a extensão pgvector.**
- C) Amazon DynamoDB com índices secundários globais.
- D) Amazon SageMaker Ground Truth para indexar vetores.

Por que B é a resposta correta



Aurora PostgreSQL
banco relacional gerenciado

- Banco relacional gerenciado da AWS
- Armazena dados estruturados e suporta consultas SQL



pgvector
extensão vetorial

- + Adiciona suporte a tipos vetoriais no PostgreSQL
- Armazena embeddings em colunas
- Consulta por similaridade usando SQL



O benefício
tudo no mesmo lugar

- Une dados estruturados e vetores no mesmo banco
- Elimina a necessidade de um banco vetorial separado
- Reduz complexidade da arquitetura

Aurora PostgreSQL é o banco relacional gerenciado da AWS. A extensão pgvector adiciona suporte a tipos vetoriais, permitindo armazenar embeddings em colunas e consultar por similaridade usando SQL. Une, no mesmo banco, dados estruturados e vetores, reduzindo a complexidade de manter um banco vetorial separado.

Tipos de Aprendizado de Máquina

Selecione DUAS afirmações CORRETAS sobre os tipos de aprendizado de máquina.

- A** O aprendizado supervisionado depende de dados previamente rotulados com a resposta correta.
- B** O aprendizado por reforço aprende observando pares de entrada e saída previamente rotulados.
- C** O aprendizado federado treina o modelo SEM centralizar os dados, preservando privacidade.
- D** O aprendizado não supervisionado exige um conjunto auxiliar de rótulos para funcionar.
- E** O aprendizado por transferência exige treinar o modelo do zero, sem aproveitar conhecimento anterior.

Tipos de Aprendizado de Máquina



A) O aprendizado supervisionado depende de dados previamente rotulados com a resposta correta.



B) O aprendizado por reforço aprende observando pares de entrada e saída previamente rotulados.



C) O aprendizado federado treina o modelo SEM centralizar os dados, preservando privacidade.



D) O aprendizado não supervisionado exige um conjunto auxiliar de rótulos para funcionar.



E) O aprendizado por transferência exige treinar o modelo do zero, sem aproveitar conhecimento anterior.

Por que A e C são as respostas corretas



Supervisionado alternativa A
aprende com rótulos

- ✓ Cada entrada tem uma resposta correta conhecida
- ✉ Detectar spam, prever preço



Federado alternativa C
treina sem mover os dados

- 📁 Distribui o treinamento entre dispositivos ou organizações
- 🛡️ Dados ficam localmente — saúde, finanças, mobile



Reforço

Aprende por tentativa e recompensa, sem rótulos prévios



Não supervisionado

Descobre padrões sem nenhum rótulo



Transferência

Reaproveita modelo pré-treinado em vez de começar do zero

Uma imobiliária deseja prever o preço de venda de imóveis a partir da área (m^2) e do bairro, modelando essa relação como uma combinação linear das variáveis de entrada. Qual técnica é a MAIS adequada?

A K-means clustering.

B Regressão Linear.

C Classificação binária com K-NN.

D Bag-of-words com TF-IDF.

A

A) K-means clustering.

✓

B) **Regressão Linear.**

C

C) Classificação binária com K-NN.

D

D) Bag-of-words com TF-IDF.

Por que B é a resposta correta



O que faz
traça a melhor reta

- ✎ Combinação linear entre variáveis de entrada e uma saída
- № Saída sempre numérica e contínua
- 🏠 Exemplo: prever preço de imóvel



Como funciona
pesos por variável

- ↑↓ Cada variável recebe um peso
- 📊 O peso indica o impacto daquela variável na saída
- 🏠 m² tem peso maior que andar no preço do imóvel



Por que usar
vantagens

- ⚡ Simples e rápida de treinar
- 👁 Interpretável — dá pra explicar cada peso
- 📋 Boa linha de base antes de modelos mais complexos

Regressão Linear traça a melhor reta (combinação linear) que descreve a relação entre variáveis de entrada e uma saída numérica contínua. A saída "preço do imóvel" é numérica → regressão. Cada variável recebe um peso indicando seu impacto. Simples, rápida e interpretável.

Um time de marketing quer segmentar a base de clientes em grupos com comportamento de compra semelhante, SEM dispor de rótulos prévios. Qual técnica deve ser utilizada?

A XGBoost para classificação multiclasse.

B K-NN supervisionado.

C Regressão Linear sobre o ticket médio.

D K-means clustering.

A

A) XGBoost para classificação multiclasse.

B

B) K-NN supervisionado.

C

C) Regressão Linear sobre o ticket médio.

✓

D) K-means clustering.

Por que D é a resposta correta



Clustering o conceito

- ☐ Agrupa observações parecidas entre si
- ✎ Sem rótulos prévios — aprendizado não supervisionado
- 🔍 Descobre estrutura escondida nos dados



K-means o algoritmo

- № Divide os dados em K grupos definidos por você
 - Cada grupo é representado por um centróide
- ⇒ Cada observação vai para o centróide mais próximo



Quando usar casos de uso

- 👤 Segmentação de clientes
- 📦 Agrupamento de produtos similares
- 👤 Perfis comportamentais

Clustering é a família que agrupa observações parecidas SEM rótulos prévios, aprendizado não supervisionado. K-means divide os dados em K grupos representados por centróides, atribuindo cada observação ao centróide mais próximo. Ideal para segmentação de clientes, produtos ou perfis comportamentais.

Classificação

Um modelo de classificação binária produz uma probabilidade para cada caso. Reduzir o limiar de decisão de 0.5 para 0.3 fará com que o modelo:

- A** Aceite MAIS casos como positivos, ficando mais sensível (mais alarmes, inclusive falsos).
- B** Aceite MENOS casos como positivos, ficando mais conservador.
- C** Elimine simultaneamente falsos positivos e falsos negativos.
- D** Não tenha nenhum efeito sobre a decisão final.

Classificação

A) Aceite MAIS casos como positivos, ficando mais sensível (mais alarmes, inclusive falsos).

B) Aceite MENOS casos como positivos, ficando mais conservador.

C) Elimine simultaneamente falsos positivos e falsos negativos.

D) Não tenha nenhum efeito sobre a decisão final.

Por que A é a resposta correta

Limiar baixo
ex.: 0,3

- ✓ Aceita mais casos como positivos
- ''' Mais sensível — Recall alto
- △ Mais alarmes falsos — Precisão cai

Limiar alto
ex.: 0,8

- ☐ Mais conservador — só aceita com alta certeza
- ⊙ Precisão alta — poucos alarmes falsos
- ☒ Pode deixar passar casos importantes — Recall cai

O limiar (intervalo) é o ponto de corte da probabilidade a partir do qual o modelo escolhe a classe positiva. Limiar mais baixo (0.3) → o modelo aceita mais casos como positivos → mais sensível, mais alarmes falsos. Limiar mais alto → mais conservador, pode deixar passar casos importantes. É um trade-off entre Recall e Precisão.



Aplicações de Classificação Binária

Selecione DUAS aplicações típicas em que a CLASSIFICAÇÃO BINÁRIA é a técnica de Machine Learning adequada.

A Prever o preço de venda de um imóvel a partir da área (m²) e da localização.

B Identificar se uma transação financeira é FRAUDE ou NÃO-FRAUDE.

C Detectar se um e-mail é SPAM ou NÃO-SPAM.

D Agrupar clientes em segmentos com comportamento de compra semelhante.

E Identificar o idioma de um texto dentre 20 idiomas possíveis.

Aplicações de Classificação Binária

☐ A) Prever o preço de venda de um imóvel a partir da área (m²) e da localização.

☒ B) Identificar se uma transação financeira é FRAUDE ou NÃO-FRAUDE.

☒ C) Detectar se um e-mail é SPAM ou NÃO-SPAM.

☐ D) Agrupar clientes em segmentos com comportamento de compra semelhante.

☐ E) Identificar o idioma de um texto dentre 20 idiomas possíveis.

Por que B e C são as respostas corretas

Classificação binária responde "a qual de DUAS categorias o exemplo pertence?" Fraude/Não-fraude (B) e Spam/Não-spam (C) são casos clássicos, apenas duas classes possíveis. As demais são outras famílias: prever preço (A) é regressão (saída numérica), agrupar clientes sem rótulos (D) é clustering, identificar idioma entre 20 possíveis (E) é classificação multiclasse.

↗ **Regressão**
alternativa A

Prever preço saída
numérica contínua, não
uma categoria

🔗 **Clustering**
alternativa D

Agrupar clientes sem
rótulos sem classes
predefinidas

🚩 **Multiclasse**
alternativa E

Identificar idioma entre 20
possíveis mais de duas
classes

*Inferência em Lote (Batch)***Selecione DUAS características da Inferência em Lote (Batch).**

- A** Processa grandes volumes de dados de uma só vez, em jobs planejados.
- B** Mantém o endpoint sempre disponível com latência de milissegundos.
- C** Geralmente apresenta MENOR custo por previsão.
- D** É a escolha ideal para detecção de fraude online em tempo real.
- E** Exige escalar a capacidade para o pico de uso contínuo, 24/7.

Inferência em Lote (Batch)

A) Processa grandes volumes de dados de uma só vez, em jobs planejados.



B) Mantém o endpoint sempre disponível com latência de milissegundos.



C) Geralmente apresenta MENOR custo por previsão.



D) É a escolha ideal para detecção de fraude online em tempo real.



E) Exige escalar a capacidade para o pico de uso contínuo, 24/7.

Por que A e C são as respostas corretas

Inferência em lote

alternativas A e C



Alternativa A

Processa grandes volumes acumulados em jobs planejados — ex.: scoring noturno de crédito



Alternativa C

Recursos alocados só durante a execução — reduz custo por previsão

Inferência em Lote (A) processa grandes volumes de dados acumulados de uma só vez, em jobs planejados (ex.: scoring noturno de crédito, relatórios). Os recursos computacionais são alocados apenas durante a execução do job (C), o que reduz o custo por previsão. As demais descrevem inferência em tempo real: endpoint sempre ativo (B), aplicações interativas como fraude online (D) e capacidade dimensionada para o pico (E).

Um modelo recebe tráfego imprevisível e intermitente, com longos períodos ocioso entre rajadas de uso. A equipe quer evitar pagar por capacidade não usada e não quer gerenciar infraestrutura. Qual opção é a MAIS adequada?

- A Amazon SageMaker Serverless Inference.
- B Endpoint provisionado 24/7 em instância EC2 P4.
- C Inferência em lote agendada de hora em hora.
- D Mechanical Turk para processar cada requisição.

✓ A) Amazon SageMaker Serverless Inference.

B) Endpoint provisionado 24/7 em instância EC2 P4.

C) Inferência em lote agendada de hora em hora.

D) Mechanical Turk para processar cada requisição.

Por que A é a resposta correta



O que é
serviço gerenciado

 SageMaker
Serverless
Inference

 Sem gerenciar
servidores ou
capacidade
manualmente



Como
funciona
automático e
elástico

 Inicia o endpoint
automaticamente
quando há
requisições

 Escala conforme o
tráfego

 Não cobra
enquanto está
ocioso



Quando usar
casos ideais

 Cargas
imprevisíveis ou
intermitentes

 Baixo volume de
requisições

 Reduz
complexidade
operacional

SageMaker Serverless Inference é um serviço gerenciado que inicia automaticamente o endpoint quando há requisições, escala conforme o tráfego e não cobra enquanto o endpoint está ocioso. Ideal para cargas imprevisíveis, intermitentes ou de baixo volume, reduz complexidade operacional e custo ocioso.

Métricas

Em um problema de classificação com classes muito desbalanceadas (poucos positivos), qual métrica equilibra Precisão e Recall em uma única medida e é recomendada para esse cenário?

A Acurácia.

B MAE (Mean Absolute Error).

C F1 Score.

D MSE (Mean Squared Error).

Métricas

A

A) Acurácia.

B

B) MAE (Mean Absolute Error).

✓

C) **F1 Score.**

D

D) MSE (Mean Squared Error).

Por que C é a resposta correta

**F1 Score**

média harmônica entre Precisão e Recall

fx Combina Precisão e Recall em um único número

△ Penaliza desequilíbrios — um lado fraco derruba o F1

🔊 Padrão em classes desbalanceadas

**A armadilha da Acurácia**

enganosa em classes desbalanceadas

⚡ 99% das amostras negativas → modelo burro que sempre diz "negativo" tem 99% de acurácia

🚫 Recall zero — nunca achou um positivo sequer

F1 Score é a média harmônica entre Precisão e Recall, penaliza desequilíbrios. Em classes desbalanceadas, a Acurácia pode ser enganosa (um modelo que sempre prevê "negativo" teria alta acurácia se 99% das amostras são negativas, mas Recall zero). MAE e MSE são métricas de regressão, não de classificação.

Matriz de Confusão

No diagnóstico médico para uma doença grave, o modelo deixou de identificar um paciente que realmente tinha a doença (classificou como saudável). Esse erro é classificado na matriz de confusão como:

A Verdadeiro Positivo (VP).

B Falso Positivo (FP).

C Verdadeiro Negativo (VN).

D Falso Negativo (FN).

Matriz de Confusão

A) Verdadeiro Positivo (VP).

B) Falso Positivo (FP).

C) Verdadeiro Negativo (VN).

✓ D) Falso Negativo (FN).

Por que D é a resposta correta

✗ **Falso Negativo**
o que é

- Modelo previu "Negativo" (saudável)
- Real era "Positivo" (doente)
- ✗ O caso real passou despercebido

💡 **Por que é caro**
diagnóstico médico

- 🔍 Paciente doente recebe alta como saudável
- 🕒 Tratamento atrasado pode ser irreversível
- ⚠️ O erro mais caro nesse tipo de aplicação

📊 **Por isso: Recall**
 $VP / (VP + FN)$

- 🔍 Mede a capacidade de capturar os positivos reais
- ✓ Recall alto = poucos doentes passando despercebidos
- 🏥 Prioridade em saúde, fraude e falhas críticas

Falso Negativo (FN): o modelo previu "Negativo" (saudável), mas o real era "Positivo" (doente). Em diagnóstico médico, FN é o erro mais caro de deixar passar um caso real de doença. Por isso, nesse tipo de aplicação, prioriza-se o Recall ($VP / (VP + FN)$), que mede a capacidade de capturar os positivos reais.

Métricas

Qual a PRINCIPAL vantagem do RMSE (Root Mean Squared Error) em relação ao MSE quando se comunica o desempenho de um modelo de regressão para áreas de negócio?

- A** RMSE é mais barato de calcular computacionalmente que o MSE.
- B** RMSE elimina completamente o efeito de outliers.
- C** RMSE está na mesma unidade da variável original, facilitando a interpretação.
- D** RMSE substitui a necessidade de calcular o R^2 .

Métricas

- A) RMSE é mais barato de calcular computacionalmente que o MSE.
- B) RMSE elimina completamente o efeito de outliers.
- C) RMSE está na mesma unidade da variável original, facilitando a interpretação.**
- D) RMSE substitui a necessidade de calcular o R^2 .

Por que C é a resposta correta

 MSE erro quadrático médio	 RMSE raiz do erro quadrático médio
↑↑ Eleva os erros ao quadrado antes de calcular a média	↓ É a raiz quadrada do MSE devolve a unidade original
 Unidade fica ao quadrado — ex.: R\$ ² em vez de R\$	 "O modelo erra em média X reais" fácil de comunicar
 Dificulta a comunicação com quem não é técnico	 Herda a sensibilidade a outliers do MSE

MSE eleva os erros ao quadrado, então a unidade resulta ao quadrado (ex.: R^2 em vez de R\$), o que dificulta a comunicação. RMSE é a raiz do MSE, retornando à unidade original da variável "o modelo erra em média X reais". Continua sensível a outliers (herdada do MSE), mas é mais intuitivo em relatórios.

Métricas

Um modelo de regressão apresentou R^2 igual a 0.85 no conjunto de validação. Qual a interpretação CORRETA desse valor?

- A O modelo erra em média 85 unidades em relação ao valor real.
- B O modelo explica aproximadamente 85% da variabilidade dos dados.
- C O modelo acerta 85% das classificações no conjunto de validação.
- D O modelo tem 85% de precisão (precision) nas classes positivas.

Métricas

- A) O modelo erra em média 85 unidades em relação ao valor real.
- B) O modelo explica aproximadamente 85% da variabilidade dos dados.**
- C) O modelo acerta 85% das classificações no conjunto de validação.
- D) O modelo tem 85% de precisão (precision) nas classes positivas.

Por que B é a resposta correta

 **O que é R^2**
coeficiente de determinação

∞ Fração da variabilidade dos dados que o modelo explica

① $R^2 = 0,85 \rightarrow$ modelo explica ~85% da variância

 **A escala**
como interpretar o valor

$R^2 = 1$ Modelo perfeito explica toda a variância

$R^2 = 0$ Equivale a sempre prever a média

$R^2 < 0$ Pior que prever a média modelo inútil

R^2 mede a fração da variabilidade dos dados que o modelo consegue explicar. $R^2 = 1 \rightarrow$ modelo perfeito (explica toda a variância). $R^2 = 0 \rightarrow$ equivale a sempre prever a média. $R^2 < 0 \rightarrow$ pior que prever a média. $R^2 = 0.85 \rightarrow$ o modelo explica ~85% da variância. Atenção: R^2 não mede erro (use RMSE) nem se aplica a classificação (use F1/Acurácia).

Explicabilidade

Sobre Partial Dependence Plots (PDPs), qual afirmação está CORRETA?

- A** São métricas numéricas de erro de regressão, como o MSE e o RMSE.
- B** São gráficos de explicabilidade que mostram, em média, o efeito de uma variável na previsão do modelo.
- C** Substituem totalmente a matriz de confusão em problemas de classificação.
- D** São aplicáveis apenas a modelos lineares, não a modelos caixa-preta.

Explicabilidade

- A** A) São métricas numéricas de erro de regressão, como o MSE e o RMSE.
- B** B) São gráficos de explicabilidade que mostram, em média, o efeito de uma variável na previsão do modelo.
- C** C) Substituem totalmente a matriz de confusão em problemas de classificação.
- D** D) São aplicáveis apenas a modelos lineares, não a modelos caixa-preta.

Por que B é a resposta correta

 O que são Partial Dependence Plots	 Como funcionam o mecanismo	 Quando usar auditoria e governança	
 Ferramentas de explicabilidade de modelos  "Em média, o que acontece com a previsão quando esta variável muda?"	 Varia o valor de uma feature...  ...mantendo todas as demais fixas  Plota a média das previsões resultantes	 Aplicável a modelos caixa-preta random forest, XGBoost, redes neurais  Fundamental para auditoria e governança em IA	PDPs são ferramentas de explicabilidade. Respondem: "em média, o que acontece com a previsão quando esta variável muda?" Variam o valor de uma feature, mantendo as demais, e plotam a média das previsões. Aplicáveis inclusive a modelos caixa-preta (random forest, XGBoost, redes neurais), fundamentais para auditoria e governança em IA.

Selecione DUAS afirmações CORRETAS sobre a família de instâncias AWS EC2 Trainium (Trn).

- A É a família otimizada para a fase de INFERÊNCIA de modelos já treinados.
- B Utiliza o chip AWS Trainium, projetado pela própria AWS.
- C É otimizada para cargas pesadas e prolongadas de APRENDIZADO de modelos de IA.
- D Foi desenhada principalmente para baixa latência em chatbots de produção.
- E Não é capaz de treinar modelos de deep learning de larga escala.

- ☐ A) É a família otimizada para a fase de INFERÊNCIA de modelos já treinados.
- ☒ B) Utiliza o chip AWS Trainium, projetado pela própria AWS.
- ☒ C) É otimizada para cargas pesadas e prolongadas de APRENDIZADO de modelos de IA.
- ☐ D) Foi desenhada principalmente para baixa latência em chatbots de produção.
- ☐ E) Não é capaz de treinar modelos de deep learning de larga escala.

Por que B e C são as respostas corretas

 Trainium para aprender	alternativas B e C
 Alternativa B Chip AWS Trainium projetado pela própria AWS	
 Alternativa C Otimizado para treinamento pesado e prolongado, incluindo deep learning de larga escala	
 Inferentia para servir	alternativas A e D
 Alternativa A Otimizada para inferência modelo já treinado gerando previsões	
 Alternativa D Baixa latência em produção	
 Alternativa E — falsa Trainium é justamente projetado para treinar deep learning em larga escala	

Trainium usa o chip AWS Trainium projetado pela própria AWS (B) e é otimizada para cargas pesadas e prolongadas de treinamento de modelos de IA, incluindo deep learning de larga escala (C). Busca alto desempenho com custo competitivo no treinamento. As demais descrevem a Inferentia: inferência (A) e baixa latência em produção (D). A alternativa E é falsa, Trainium é justamente desenhada para treinar deep learning em larga escala. Regra: Trainium para aprender, Inferentia para servir.



Fim do Simulado

Bons estudos para a AWS Certified AI Practitioner (AIF-C01)

20

Questões respondidas

05

Encontros revisados

Revise os pontos errados antes da próxima aula